

République Algérienne Démocratique et Populaire
Ministère de l'Enseignement Supérieur et de la Recherche Scientifique
Université des Sciences et de la Technologie Houari Boumediene



Faculté d'Informatique
Département : IA & SD



Rapport De Stage

Spécialité :
Informatique Générale

Thème

Détection des anomalies cardiaques à partir des ECG
en utilisant l'Intelligence Artificielle

Organisme d'accueil : CERIST

Sujet proposé par :

M. Aliradi Rachid

Présenté par :

ACHEROUF KEBIR Sarah

BELLAZOUZ Nour el imane

CHOHRA Inès

DJOUABI Nassiba

ZIANE BERROUDJA Tesnime

Soutenu le : 02/06/2025

Devant le jury composé de :

M^{me} TAMEN Zahia

Présidente

M^{me} BENSEBAA Amina

Membre

Remerciements

Nous exprimons notre profonde gratitude à **Allah** pour nous avoir donné la force, la persévérance et la guidance tout au long de ce projet. Sans Sa bénédiction, ce travail n'aurait pas pu voir le jour.

Nous remercions très chaleureusement **Monsieur Ali Radi Rachid**, notre encadrant au CERIST, pour ses conseils avisés, son soutien constant et son expertise remarquable dans le développement de ce projet sur la détection des anomalies cardiaques par intelligence artificielle. Sa disponibilité, sa patience et ses orientations précieuses ont été déterminantes pour la réussite de notre travail. Nous avons eu l'honneur de bénéficier de son expérience et de sa vision scientifique.

Nous adressons également nos sincères remerciements à **Madame Tamen Zahia** et **Madame Bensebaa Amina**, membres éminents du jury, pour avoir accepté d'évaluer notre travail avec rigueur et bienveillance. Leur temps précieux, leur expertise reconnue et leurs observations constructives nous honorent grandement et contribuent à l'amélioration de notre recherche.

Nous exprimons notre profonde reconnaissance envers le **Centre de Recherche sur l'Information Scientifique et Technique (CERIST)** pour nous avoir accueillis dans ses prestigieux locaux et pour avoir mis à notre disposition un environnement de travail exceptionnel, propice à la réalisation de ce stage. L'accès aux ressources technologiques de pointe, aux bases de données spécialisées et aux infrastructures de recherche de ce centre d'excellence a été essentiel à l'accomplissement de notre projet.

Nous remercions également l'ensemble des enseignants du département d'informatique de **l'USTHB**, pour la qualité de l'enseignement dispensé durant notre parcours universitaire.

Enfin, nos remerciements les plus sincères s'adressent à tous ceux qui, de près ou de loin, ont contribué à la réalisation de ce projet ambitieux : nos familles pour leur soutien indéfectible, nos enseignants pour leur formation de qualité, et tous ceux qui ont participé à notre développement académique et professionnel. Leur confiance et leurs encouragements ont été une source de motivation constante.

Table des matières

1	État de l’art	8
1.1	Introduction	8
1.2	Anatomie du cœur	8
1.2.1	Présentation	8
1.2.2	Activité électrique du cœur ECG	8
1.3	L’électrocardiogramme (ECG)	8
1.3.1	Caractéristiques du signal ECG	8
1.4	Les Arythmies Cardiaques	9
1.5	L’intelligence artificielle	9
1.6	Computer vision et le traitement d’image	9
1.7	L’Apprentissage Automatique	10
1.8	L’Apprentissage Profond (DL)	10
1.8.1	Neurones artificielles	10
1.8.2	Réseau de neurones	10
1.8.3	Qu’est-ce que le Deep Learning ?	10
1.9	Analyse comparative	12
1.10	Conclusion	12
2	LA CONCEPTION	13
2.1	Introduction	13
2.2	Architecture du système	13
2.3	Prétraitements	14
2.3.1	Correction de la ligne de base	14
2.3.2	Filtrage	14
2.3.3	Normalisation	15
2.3.4	Segmentation	16
2.4	Augmentation des données	17
2.5	Procédure de traitement d’images et conversion en signaux	17
2.5.1	Méthodologie	17
2.6	Modèle de classification	17
2.6.1	méthodologie de conception	17
2.6.2	Architecture et description du modèle	18
2.6.3	Entraînement	19
2.7	Le site web CardioNet	19
2.8	Conclusion	19
3	Discussion des Résultats	20
3.1	Introduction	20
3.2	Environnement de développement	20
3.2.1	Langage de programmation et bibliothèques	20
3.2.2	Environnements d’exécution	20
3.3	Base de données utilisée	21
3.4	Critères d’évaluation	21
3.4.1	Évaluation de l’extraction du signal	21

3.4.2	Évaluation du modèle de classification	22
3.5	Résultats du traitement d'image	22
3.6	Résultats et évaluation des modèles	23
3.6.1	Modèle et configurations de données	23
3.7	Matrice de confusion	26
3.8	Comparaison des performances avec l'état de l'art	27
3.9	Présentation de l'interface	27
3.10	Conclusion	27
A	l'état de l'art	33
A.1	détails des arytmies	33
A.1.1	Bradycardies	33
A.1.2	Tachycardies	33
A.1.3	Troubles Ventriculaires	33
A.2	Architectures d'un cnn	34
A.3	ML vs DL :	34
B	Conception	36
B.1	Méthodes d'augmentation	36
B.2	Architecture détaillée du modèle CNN	36
B.3	Les diagrammes :	37
C	Discussion des Résultat :	39
C.1	Hardware :	39
C.1.1	Technologies web et base de données	39
C.2	Tableau récapitulatif des performances des modèles :	39
C.3	Procéssus de classification final d'un ecg	40
C.4	Présentation de l'interface :	40

Table des figures

1.1	Système de conduction électrique du cœur et signal ECG [5]	9
1.2	Neurone biologique et artificiel [15]	10
1.3	Fonctionnement de la convolution [25]	11
2.1	Architecture du pipeline ECG avec CNN 1D	13
2.2	Signal ECG avant correction ligne de base	14
2.3	après correction ligne de base	14
2.4	Signal ECG avant filtrage	15
2.5	Signal ECG après filtrage	15
2.6	Signal ECG avant normalisation	16
2.7	Signal ECG après normalisation	16
2.8	Exemples de segments ECG pour chaque classe AAMI	16
2.9	Diagramme de l'architecture CNN utilisée pour la classification	18
3.1	Image ECG d'origine	22
3.2	Signal ECG extrait	23
3.3	Courbes de loss et d'accuracy- Modèle 1 (CNN sans augmentation).	23
3.4	Courbes de loss et d'accuracy- Modèle 2 (CNN avec 1k/classe)	24
3.5	Courbes de loss et d'accuracy- Modèle 3 (CNN avec 10k/classe).	25
3.6	Courbes d'entraînement- Modèle CNN-GRU	25
3.7	Courbes d'entraînement- Modèle CNN-LSTM	26
3.8	Matrice de confusion	26
3.9	Interface d'analyse automatique ECG	27
A.1	Architecture de base d'un CNN	34
B.1	Diagrammes de cas d'utilisation.	37
B.2	Diagrammes de classes.	37
B.3	Diagramme de séquence.	38
C.1	page d'accueil.	40
C.2	Interface historique des patients — affichage des résultats médicaux.	41
C.3	Interface historique des patients — affichage des résultats médicaux.	41

Liste des équations

2.1 MinMax Normalization	15
3.1 Racine de l'erreur quadratique moyenne (RMSE)	21
3.2 Erreur absolue moyenne (MAE)	21
3.3 Coefficient de corrélation de Pearson (r)	22
3.4 Accuracy	22
3.5 Précision	22
3.6 Rappel	22
3.7 Moyenne harmonique entre la précision et le rappel	22

Liste des tableaux

1.1	Études sur les approches Deep Learning	12
3.1	Classification AAMI des battements cardiaques et répartition	21
3.2	Performances du modèle CNN sans augmentation de données	24
3.3	Performances d'un modèle complémentaire	24
3.4	Performances du modèle CNN avec augmentation intensive (10k/classe).	25
3.5	Performances des modèles hybrides	26
3.6	Comparaison des performances de différentes études de classification ECG	27
A.1	Comparaison des études sur la détection d'arythmies	34
A.2	Comparaison entre ML et DL	35
B.1	Architecture détaillée du modèle CNN	36
C.1	Performances des différents modèles de classification ECG	39

Introduction Générale

Les maladies cardiovasculaires (MCV) sont la première cause de mortalité dans le monde, avec plus de 17,7 millions de décès en 2017 selon l’OMS. Parmi elles, les arythmies cardiaques constituent un enjeu majeur, pouvant entraîner des complications graves, voire des décès soudains. L’ECG, outil non invasif et largement utilisé, permet de capturer l’activité électrique du cœur et d’identifier des anomalies telles que les troubles du rythme cardiaque. Cependant, son analyse repose encore largement sur l’expertise humaine, une méthode exigeante, sujette à des erreurs et limitée par la disponibilité des spécialistes, ce qui peut retarder le diagnostic et l’accès aux soins.

L’intelligence artificielle (IA) offre une solution efficace pour automatiser cette analyse. En exploitant les signaux ECG, ces approches permettent une classification rapide et précise des arythmies, allégeant la charge des médecins et facilitant une détection précoce.

Dans le cadre de ce travail, nous proposons une approche automatisée pour la classification des arythmies ECG, basée sur le Deep Learning (DL) avec pour objectif d’améliorer la précision du diagnostic et d’optimiser la prise en charge des patients atteints de troubles du rythme cardiaque. Suite à cette introduction, notre manuscrit sera organisé comme suit :

Chapitre 1 : État de l’art Dans ce chapitre, nous présenterons quelques notions générales sur le cœur, les arythmies cardiaques, des généralités sur l’intelligence artificielle ainsi que quelques travaux réalisés pour la détection automatique des anomalies cardiaques.

Chapitre 2 : Conception

Nous expliquerons dans ce chapitre les différentes étapes de la conception de notre système : les prétraitements apportés à nos données, la structure de notre modèle ainsi que le processus de classification d’une donnée en entrée.

Chapitre 3 : Discussion des résultats

Ce dernier chapitre sera consacré à l’évaluation et l’implémentation de notre modèle, où l’on présentera l’environnement de développement et les bibliothèques utilisées, les différentes mesures statiques choisies pour l’évaluation. Pour ensuite comparer plusieurs configurations de modèles, afin d’en choisir le plus performant. Et pour finir, nous verrons l’interface développée, qui nous permettra d’interagir avec le système de manière plus intuitive.

Enfin, Nous clôturerons ce manuscrit avec une conclusion générale.

Chapitre 1

État de l'art

1.1 Introduction

Pour la réalisation d'un modèle de détection des anomalies cardiaques, il faut définir certaines notions liées au domaine. Nous présentons dans ce chapitre un aperçu sur l'anatomie du cœur, le suivi de son activité avec l'électrocardiogramme et les différents types d'anomalies cardiaques. Enfin, nous verrons l'utilisation des méthodes d'intelligence artificielle pour la détection de ces anomalies.

1.2 Anatomie du cœur

1.2.1 Présentation

Le cœur est un muscle creux situé entre les poumons. Il a quatre parties : en haut, l'oreillette droite reçoit le sang pauvre en oxygène des principales veines du corps, tandis que l'oreillette gauche reçoit le sang oxygéné des poumons. En bas, le ventricule droit envoie le sang vers les poumons par l'artère pulmonaire, et le ventricule gauche envoie le sang oxygéné vers le reste du corps via l'aorte [1].

1.2.2 Activité électrique du cœur ECG

La contraction du cœur est gérée par un signal électrique interne. Le nœud sinusal, situé dans l'oreillette droite, le génère puis l'envoie aux oreillettes, déclenchant ainsi leur contraction. Le signal atteint le nœud auriculo-ventriculaire (NAV), qui ralentit légèrement sa transmission afin de permettre le bon remplissage des ventricules. Il est ensuite conduit vers ces derniers via le faisceau de His et les fibres de Purkinje. La perturbation de ce processus peut entraîner des arythmies cardiaques [2].

1.3 L'électrocardiogramme (ECG)

L'ECG est un examen médical qui enregistre l'activité électrique du cœur en détectant les changements du signal électrique captés par des électrodes placées sur la peau. Ce signal, composé d'une suite d'ondes, reflète les différentes phases de l'activité cardiaque au cours de chaque battement [3].

1.3.1 Caractéristiques du signal ECG

Les principales ondes sont :

- **Onde P** : activation des oreillettes.
- **Complexe QRS** : activation des ventricules.

- Q : activation du septum,
- R : activation principale des ventricules,
- S : fin de l'activation.
- **Onde T** : retour au repos des ventricules.
- **Onde U (facultative)** : associée aux muscles papillaires.

Fréquence cardiaque

Représente le nombre de battements par minute, calculé à partir de la distance entre les complexes QRS. Ces caractéristiques permettent d'analyser le cœur et de détecter les arythmies [4].




FIGURE 1.1 – Système de conduction électrique du cœur et signal ECG [5]

1.4 Les Arythmies Cardiaques

Les arythmies cardiaques sont des troubles du rythme touchant la fréquence et le rythme des battements cardiaques. Elles se classent en bradycardies (rythme lent), tachycardies (rythme rapide) et troubles ventriculaires (troubles du rythme pouvant mener à un arrêt cardiaque) [6]. Une classification plus détaillée est présentée en annexe A.1.

1.5 L'intelligence artificielle

L'intelligence artificielle (IA) désigne l'ensemble des techniques qui permettent à une machine de réaliser des tâches normalement réservées à l'intelligence humaine, comme comprendre une langue, résoudre des problèmes ou apprendre à partir de sa propre expérience. Elle est utilisée lorsqu'il n'existe pas de méthode simple ou automatique pour accomplir une tâche. L'IA donc modélise certaines formes d'intelligence à travers des programmes informatiques [7]. Elle regroupe plusieurs sous-domaines, comme le Machine Learning (ML) et le Deep Learning (DL).

1.6 Computer vision et le traitement d'image

La vision par ordinateur est un domaine au croisement de l'IA et du traitement d'image. Elle permet aux machines d'interpréter et analyser des données visuelles. Elle s'appuie sur des techniques de traitement d'image, qui consistent à appliquer une série d'opérations sur les images afin d'en améliorer la qualité ou d'en extraire des informations. Ce processus suit généralement plusieurs étapes : acquisition, traitement et génération de résultats exploitables [8].

1.7 L'Apprentissage Automatique

Le machine learning (ML) est une branche de l'IA qui permet à une machine d'apprendre sans être programmée explicitement. Il se divise en deux types : l'apprentissage supervisé où les données sont étiquetées, et l'apprentissage non supervisé où elles ne le sont pas [9]. Pour détecter les anomalies dans l'ECG, les méthodes de ML extraient manuellement les caractéristiques de ce dernier, puis utilisent des modèles de classification. Des méthodes sont présentées dans le tableau (voir Annexe A).

Dans notre travail, nous nous focaliserons sur l'apprentissage supervisé.

1.8 L'Apprentissage Profond (DL)

1.8.1 Neurones artificielles

Un neurone artificiel fonctionne comme un neurone biologique, il reçoit des valeurs en entrée, calcule leur somme pondérée (à laquelle il ajoute un biais), puis la transforme par une fonction d'activation. Le résultat obtenu est la sortie du neurone, qui est ensuite transmise aux autres neurones du réseau [14].




FIGURE 1.2 – Neurone biologique et artificiel [15]

1.8.2 Réseau de neurones

Un RNA est un modèle informatique inspiré du cerveau humain. Il est composé de couches de neurones connectés entre eux, on retrouve la couche d'entrée, une ou plusieurs couches cachées et une couche de sortie. Chaque connexion a un poids qui détermine la transmission de l'information. Le RNA apprend en ajustant ses poids lors de l'apprentissage supervisé, via l'algorithme de rétropropagation [16]. Une fois entraîné, il peut prédire ou classifier de nouvelles données [17].

1.8.3 Qu'est-ce que le Deep Learning ?

Le DL est une sous-catégorie du ML basée sur les RNA. Il permet à un système d'apprendre automatiquement des représentations complexes à partir de grandes quantités de données, en exploitant l'organisation en couches profondes de neurones. Cette approche offre une meilleure capacité d'adaptation et de tolérance aux erreurs [18].

Architectures de deep learning

a. Réseaux de Neurones Récurrents (RNN) :

Les RNN sont des modèles de DL conçus pour traiter des données séquentielles à l'aide d'une mémoire interne pour stocker les informations des étapes précédentes. Cependant, ils sont confrontés au

problème de la disparition du gradient [19] . Des variantes comme LSTM et GRU ont été développées pour résoudre ces problèmes [20].

Long Short-Term Memory (LSTM) :

Les LSTM retiennent les informations importantes et oublient les moins pertinentes grâce à des portes spécialisées [21]. Ils sont composés de plusieurs unités récurrentes, chacune contenant :

- Une porte d'entrée (input gate) : contrôle quelles informations ajouter à la mémoire.
- Une porte d'oubli (forget gate) : contrôle quelles informations supprimer.
- Une porte de sortie (output gate) : choisit les informations à utiliser pour la sortie du modèle.

Gated Recurrent Unit (GRU) :

Les GRU utilisent deux portes principales : la porte de mise à jour, qui conserve les informations pertinentes et la porte de réinitialisation, qui supprime les données non importantes. Plus simple et rapide que le LSTM, et est moins gourmand en mémoire [19].

c. Les réseaux de neurones convolutifs (CNN) :

Les CNN sont un type de RNA inspirés du fonctionnement du cortex visuel humain. Ils sont conçus pour traiter des données structurées en grille, comme les images ou les signaux temporels, ce qui les a rendus largement utilisés dans des domaines [22, 23] tels que le computer vision, la reconnaissance et classification d'images et de signaux. Ils se composent principalement de 3 types de couches comme l'illustrées à la figure A.2

- Couche de convolution :

La couche clé du réseau CNN, elle applique des filtres (kernels) qui parcourent l'entrée matricielle image ou signal, pour en extraire les caractéristiques essentielles (contours et textures). Le résultat est une carte d'activation 'feature map' [24], qui contient les éléments extraits.




FIGURE 1.3 – Fonctionnement de la convolution [25]

Avec I : la matrice entrée (image/signal), K : le kernel convolutif, $I * K$: la carte d'activation.

-Couche de pooling :

Elle sert à réduire la taille des cartes d'activation, ce qui diminue le nombre de paramètres et accélère le traitement. Il en existe deux types principaux, le max pooling, qui garde la valeur maximale d'une région donnée, et l'average pooling et mean pooling, qui en calcule la moyenne [26].

- **Couche entièrement connectée (Fully Connected Layer) :**

Toutes les couches précédentes. Son nombre de neurones correspond au nombre de classes en sortie. Elle combine les caractéristiques extraites pour calculer un score pour chaque classe, puis utilise une fonction d'activation [27] pour obtenir des probabilités. La classe ayant la probabilité la plus élevée est choisie comme résultat [28].

TABLE 1.1 – Études sur les approches Deep Learning

Approche DL	Étude	Méthodes	Dataset	Type de données	Précision	Accuracy
CNN	Xuan Huaet al. [29]	Segmentation + CNN classique	MIT-BIH, AFDB, VFDB	Signal 1D	96.5	97.31
CNN	Liu et al [30]	Segmentation + CNN classique	MIT-BIH, AFDB, VFDB	Signal 1D	96.5	97.31
CNN + LSTM	Zabihi et al [31]	ResNet + Random Forest	MIT-BIH	Signal	96.03	99.26
CNN + GRU	Wang et al[32].	CWT + SMOTE + extraction 2D	EFEDA, MIT-BIH	Image 2D	99.33	98.00

1.9 Analyse comparative

D'après les études traitant des méthodes de ML et de DL, nous avons réalisé un tableau comparatif entre les deux approches en termes de résultats cités dans (A.3). Bien que les méthodes classiques ML donnent de bons résultats, les méthodes DL les surpassent en performance. Cela fait d'eux le choix le plus optimal.

1.10 Conclusion

Dans ce chapitre, nous avons abordé les notions fondamentales en lien avec l'anatomie cardiaque, le fonctionnement du cœur, l'ECG et les différentes arythmies. Nous avons également exploré les concepts clés de l'intelligence artificielle, du machine learning et du deep learning, notamment les CNN, sur lesquels repose notre approche. Enfin, nous avons brièvement passé en revue des études antérieures, ce qui nous permet de mieux contextualiser notre propre modèle de classification présenté dans le chapitre suivant.

Chapitre 2

LA CONCEPTION

2.1 Introduction

Ce chapitre est consacré à la présentation de notre système, pour ce faire nous le divisons en trois parties. D'abord, les différentes étapes de prétraitement, ensuite le traitement d'image appliqué au tracé ECG et l'extraction des informations. Enfin, le modèle de classification CNN ainsi que la procédure de son entraînement.

2.2 Architecture du système

L'organigramme suivant décrit l'architecture et les étapes générales de notre système, depuis l'entrée du signal ECG, en passant par le prétraitement, jusqu'à sa transmission au modèle de classification CNN, chargé de le classer dans une des cinq catégories F, Q, S, N et V. tikz




FIGURE 2.1 – Architecture du pipeline ECG avec CNN 1D

2.3 Prétraitements

Le signal ECG obtenu lors de l'enregistrement est souvent contaminé avec différentes sources de bruits : techniques, physiques et pathologique pouvant modifier ses caractéristiques, et parfois induire en erreur le diagnostic final. C'est pourquoi il est essentiel d'appliquer certains prétraitements à nos données afin d'améliorer leur exploitation par le modèle et garantir une classification fiable. Dans notre travail, nous avons utilisé la base de données MIT-BIH Arrhythmia Database[33], une référence largement utilisée dans les recherches sur l'analyse ECG.

2.3.1 Correction de la ligne de base

La ligne de base correspond à la ligne isoélectrique du cœur, observée sur un ECG au repos. Cette ligne peut se décaler à cause de la respiration, des mouvements du patient ou d'autres interférences. Ce phénomène, appelé dérive de la ligne de base (Baseline Wander), est éliminé en utilisant le filtre de Savitzky-Golay qui lisse et recentre le signal autour de sa ligne de base réelle sans le déformer [34].




FIGURE 2.2 – Signal ECG avant correction ligne de base




FIGURE 2.3 – après correction ligne de base

2.3.2 Filtrage

Pour supprimer le bruit du signal ECG, nous utilisons la transformée en ondelettes discrète (DWT) [35] avec l'ondelette Daubechies 4 (db4) [36]. Grâce à sa décomposition sur 3 niveaux, cette méthode découpe le signal en composantes fréquentielles, puis applique un seuil doux pour éliminer les parties bruitées, notamment celles à haute fréquence [37].




FIGURE 2.4 – Signal ECG avant filtrage




FIGURE 2.5 – Signal ECG après filtrage

Le bruit haute fréquence présent dans le signal original (courbe supérieure) est considérablement réduit après filtrage (courbe inférieure), préservant les caractéristiques morphologiques importantes

2.3.3 Normalisation

La normalisation consiste à ajuster les amplitudes des signaux ECG dans une plage spécifique, harmonisant ainsi les données car les amplitudes varient considérablement d'un patient à un autre. Nous utilisons la normalisation Min-Max [38] qui transforme une valeur A en une valeur B selon la formule :

$$B = a + \frac{(A - \min(A)) \cdot (b - a)}{\max(A) - \min(A)} \quad (2.1)$$

Where $[a, b] = [-1, 1]$ représente l'intervalle cible de normalisation, A est la valeur originale, $\min(A)$ et $\max(A)$ sont respectivement les valeurs minimale et maximale du signal original, a est la borne inférieure de la plage cible (souvent 0), b est la borne supérieure de la plage cible (souvent 1) et B la valeur normalisée dans l'intervalle $[a, b]$




FIGURE 2.6 – Signal ECG avant normalisation




FIGURE 2.7 – Signal ECG après normalisation

L'amplitude du signal original (courbe supérieure) est ramenée dans l'intervalle $[-1, 1]$

2.3.4 Segmentation

La segmentation permet de découper le signal en battements individuels utilisables comme entrées pour le modèle. Cette approche, largement adoptée dans la littérature [39], consiste à centrer chaque segment autour d'un pic R correspondant au sommet d'un battement cardiaque. Pour chaque pic, nous extrayons une seconde de signal (360 échantillons à 360 Hz), répartie équitablement avant et après ce point. Si le sommet est trop proche du début ou de la fin du signal, nous appliquons un remplissage par zéros (zero-padding). Chaque segment conserve l'étiquette du battement dont il provient.




FIGURE 2.8 – Exemples de segments ECG pour chaque classe AAMI .

2.4 Augmentation des données

L'augmentation de données consiste à augmenter artificiellement la taille du jeu d'entraînement afin de corriger le déséquilibre entre classes et pallier le surapprentissage. Pour équilibrer les classes dans le dataset MIT-BIH, nous avons appliqué une stratégie d'augmentation ciblée : si une classe est sous-représentée, elle est augmentée jusqu'à un seuil défini, si elle est surreprésentée, elle est réduite. Chacune des 5 classes (« N », « S », « V », « F » et « Q ») contiennent donc 10 000 segments, et cela en appliquant des méthodes d'augmentation classiques [40] aléatoirement sur le segment, comme l'ajout de bruit gaussien, décalages temporels, étirements ou compressions temporelles, variations d'amplitude. Ces méthodes classiques utilisées sont expliquées dans la partie B.1 .

2.5 Procédure de traitement d'images et conversion en signaux

Nous avons constaté que les médecins utilisent souvent les images des tracés ECG, qui sont la norme de stockage en Algérie. Cela nous a poussés à développer un algorithme pour extraire le signal à partir d'images, facilitant ainsi leur utilisation et élargissant les domaines d'application [41].

2.5.1 Méthodologie

a) Traitement d'images

L'image est d'abord convertie en niveaux de gris : réduire ses couleurs à des nuances de gris. Ensuite le contraste est renforcé pour faire ressortir la courbe. Enfin, elle est binarisée (transformée en noir et blanc) pour isoler le tracé ECG et enlever le parasitage.

b) Extraction du signal

Parcourir chaque colonne de pixels pour détecter la position du pixel noir qui correspond au tracé, ainsi construire un vecteur 1D représentant le signal ECG.

c) Post-traitement

Le signal est lissé à l'aide d'un filtre gaussien, normalise et filtré entre 1–40 Hz, suivie d'une interpolation pour corriger les zones irrégulières.

2.6 Modèle de classification

2.6.1 méthodologie de conception

Dans cette section, nous présentons la conception de notre modèle de classification ECG basé sur un CNN. Pour avoir les meilleures performances, nous avons commencé avec une architecture simple composée de trois blocs CNN. Ensuite, nous avons utilisé Keras Tuner [42], un outil d'optimisation de paramètres similaire à Grid Search [43]. Il permet de tester différentes combinaisons d'hyperparamètres selon la métrique définie, dans notre cas le F1-score afin de trouver la configuration optimale. D'autres tests ont été faits en ajustant manuellement les paramètres, ce qui a abouti à l'architecture suivante :

2.6.2 Architecture et description du modèle




FIGURE 2.9 – Diagramme de l’architecture CNN utilisée pour la classification

Partie convolutionnelle (extraction des caractéristiques)

1. Le segment ECG d’entrée contient 360 échantillons.
2. Trois blocs convolutionnels successifs sont appliqués suivant cette séquence :
 - Conv1D avec 48 à 64 filtres de taille 3 ou 5, pour extraire les motifs caractéristiques du signal (ondes P, QRS, T).
 - BatchNormalization pour stabiliser et accélérer l’apprentissage en normalisant les activations[46].
 - MaxPooling1D avec une fenêtre de taille 2, réduisant la dimension temporelle.
 - Dropout à 25 % régularise et désactive aléatoirement des neurones pour limiter le surapprentissage.
3. Après ces trois blocs, la sortie est une matrice de taille 42×64 , contenant des caractéristiques complexes et pertinentes du signal.

Partie classification dense

1. La sortie des convolutions (taille 42×64) est aplatie par la couche Flatten en un vecteur de 2688 éléments. Ce vecteur est passé dans une couche Dense de 96 neurones avec fonction ReLU pour

combiner les informations.

2. Un Dropout de 50 % est appliqué pour éviter le surapprentissage [47].
3. La couche Dense fully connected avec 5 neurones et activation Softmax produit la probabilité pour chaque classe de sortie N, S, V, F et Q :
 - Le modèle génère un vecteur de probabilités indiquant la probabilité que le segment appartienne à chaque classe. La classe prédite est celle ayant la probabilité maximale.

Une architecture plus détaillée du modèle est donnée dans (B.1)

Fonctions utilisées

- **Fonction d'activation** : ReLU [44] est utilisée dans toutes les couches cachées pour favoriser l'apprentissage rapide et efficace, tandis que la couche finale utilise Softmax pour convertir les scores en probabilités.
- **Fonction de perte** : Sparse Categorical Crossentropy [45] adaptée aux problèmes de classification multi-classes avec des étiquettes entières.

L'architecture détaillée du modèle CNN proposé est présentée en Annexe 2.9.

2.6.3 Entraînement

Le modèle a été entraîné sur un jeu de données divisé en train set et validation set, respectivement selon le ratio 80 % et 20 %. Nous avons testé plusieurs versions de ce dataset voir décrit dans la section 2.4 et finalement choisi un seuil de 10 000 segments par classe. Les hyperparamètres utilisés sont :

- Algorithme d'optimiseur Adam [49] avec un taux d'apprentissage $\alpha = 10^{-3}$, et une régularisation par poids des classes afin de les équilibrer pendant l'entraînement.
- Des callbacks appliqués pour éviter l'overfitting et arrêter l'entraînement avant la fin des époques si nécessaire [48] :
 - EarlyStopping : stoppe l'entraînement si l'accuracy stagne.
 - ReduceLROnPlateau : réduit le taux d'apprentissage si besoin.
 - F1ScoreCallback : suit le F1-score à chaque époque.

2.7 Le site web CardioNet

Pour que notre travail soit exploitable, nous avons conçu un site web spécialement pour les cardiologues, dans le but de leur faire profiter des fonctionnalités que nous proposons, essentiellement la classification d'un ECG d'un patient. Ce site web est basé sur des diagrammes UML, cités en détail en annexe(B.3)

2.8 Conclusion

Pour conclure, ce chapitre a présenté les différentes étapes de conception de notre système de classification des anomalies cardiaques. Celui-ci peut prendre en entrée soit un signal ECG brut, soit une image du tracé. Quelle que soit la nature de l'entrée, les prétraitements adéquats sont appliqués afin d'obtenir un signal exploitable par notre modèle CNN. Concernant ce dernier, nous avons décrit son architecture, le choix des hyperparamètres ainsi que son entraînement. Le chapitre suivant abordera l'environnement de développement, les résultats obtenus, ainsi que l'interface utilisateur.

Chapitre 3

Discussion des Résultats

3.1 Introduction

Dans ce chapitre, nous présentons l'environnement dans lequel notre projet a été réalisé. Cela comprend les ressources matérielles et logicielles utilisées, les outils de développement et d'exécution ainsi que la base de données utilisée. De plus, nous exposons les performances de notre système incluant le modèle de classification, à l'aide de certaines métriques standards d'évaluation. Enfin on passe à la présentation de l'interface utilisateur.

3.2 Environnement de développement

3.2.1 Langage de programmation et bibliothèques

- **Python 3.9** : Langage de programmation de haut niveau pour l'intelligence artificielle et l'analyse de données.
- **NumPy 1.21.0** : Bibliothèque pour la manipulation de tableaux multidimensionnels et calculs numériques.
- **SciPy 1.7.0** : Extension de NumPy pour le traitement du signal et l'analyse statistique.
- **WFDB 4.0.0** : Bibliothèque spécialisée pour la gestion des signaux physiologiques ECG [50].
- **TensorFlow 2.8.0** : Framework de deep learning pour la création de modèles d'apprentissage profond.
- **Keras** : API de haut niveau intégrée à TensorFlow pour la construction de réseaux de neurones.
- **Scikit-learn 1.0.2** : Bibliothèque d'outils de machine learning et de prétraitement des données.
- **Matplotlib 3.5.0 / Seaborn 0.11.0** : Bibliothèques de visualisation de données en Python.

Les différentes technologies web et outils de base de données ainsi que le hardware utilisés dans ce projet, sont décrits respectivement en détail dans l'annexe, section Technologies web et base de données (voir Annexe C.1.1 C.1).

3.2.2 Environnements d'exécution

- **Visual Studio Code** : Un éditeur de code destiné au développement local et à l'exécution de scripts. Il est compatible avec plusieurs systèmes et prend en compte plusieurs langages ce qui le rend flexible et pratique.
- **Google Colab** : Environnement de développement en ligne créé par Google, basé sur Jupyter Notebook. Il permet d'exécuter du code Python dans le cloud sans configuration locale, offrant ainsi la possibilité d'utiliser un GPU gratuitement pour une durée limitée.

3.3 Base de données utilisée

Dans cette étude, nous utilisons la base de données MIT-BIH Arrhythmia Database de PhysioNet [51]. Elle contient 48 enregistrements ECG d'environ 30 minutes, issus de 47 patients, échantillonnés à 360 Hz avec une résolution de 11 bits sur une plage de 10 mV. Les battements sont annotés et validés par au moins deux cardiologues.

Pour regrouper les battements, nous avons adopté la classification AAMI (Association for the Advancement of Medical Instrumentation) [52], une norme médicale reconnue qui les organise en cinq classes principales : N, S, V, F et Q.

Cette base est largement utilisée comme référence dans la littérature scientifique, ce qui facilite la comparaison avec d'autres travaux. Elle est aussi bien documentée, accessible et adaptée aux projets à ressources limitées, constituant donc le choix le plus adapté à nos objectifs. Les détails de la classification AAMI et la répartition des battements .

TABLE 3.1 – Classification AAMI des battements cardiaques et répartition

Classe AAMI	Battements MIT-BIH	Nombre de battements
N (Normaux)	N, L, R, e, j	82 424
S (Supraventriculaires)	A, a, J, S	2 749
V (Ventriculaires)	V, E	7 159
F (Fusion)	F	798
Q (Inconnus)	/, f, Q	8 043

3.4 Critères d'évaluation

3.4.1 Évaluation de l'extraction du signal

Pour évaluer et valider le signal extrait, celui-ci est comparé à un signal de référence provenant de la base de données MIT-BIH. Trois métriques sont utilisées pour cette comparaison :

Racine de l'erreur quadratique moyenne (RMSE)

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (3.1)$$

où y_i représente la valeur réelle, $\hat{y}_i$ la valeur estimée, et n le nombre total d'échantillons.

Erreur absolue moyenne (MAE)

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (3.2)$$

Cette métrique reflète la moyenne des écarts absolus entre les valeurs réelles et estimées.

Coefficient de corrélation de Pearson (r)

$$r = \frac{\sum_{i=1}^n (y_i - \bar{y})(\hat{y}_i - \bar{\hat{y}})}{\sqrt{\sum_{i=1}^n (y_i - \bar{y})^2} \sqrt{\sum_{i=1}^n (\hat{y}_i - \bar{\hat{y}})^2}} \quad (3.3)$$

où $\bar{y}$ et $\hat{\bar{y}}$ sont respectivement les moyennes des valeurs réelles et estimées.

3.4.2 Évaluation du modèle de classification

Pour l'évaluation de notre modèle, nous nous sommes basés sur des métriques standards en IA, dérivées de la matrice de confusion. L'accuracy donne une indication sur la performance globale, tandis que la précision, le rappel et le F1-score permettent une évaluation par classe. Ces métriques représentent :

Soit **VP** : Vrai positif, **VN** : Vrai négatif, **FP** : Faux positif, **FN** : Faux négatif.

— **Accuracy (Exactitude)** : Le taux de bonnes prédictions sur l'ensemble des classes.

$$\text{Accuracy} = \frac{\text{VP} + \text{VN}}{\text{VP} + \text{VN} + \text{FP} + \text{FN}} \quad (3.4)$$

— **Précision** : Le taux des vraies occurrences parmi toutes celles prédites comme positives.

$$\text{Précision} = \frac{\text{VP}}{\text{VP} + \text{FP}} \quad (3.5)$$

— **Rappel (Sensibilité)** : La capacité du modèle à retrouver toutes les occurrences positives.

$$\text{Rappel} = \frac{\text{VP}}{\text{VP} + \text{FN}} \quad (3.6)$$

— **F1-Score** : Moyenne harmonique entre la précision et le rappel.

$$\text{F1-Score} = 2 \times \frac{\text{Précision} \times \text{Rappel}}{\text{Précision} + \text{Rappel}} \quad (3.7)$$

3.5 Résultats du traitement d'image

Nous avons testé notre méthode de traitement et d'extraction de signal sur une image fournie par le service de cardiologie de l'hôpital Mustapha Bacha :




FIGURE 3.1 – Image ECG d'origine




FIGURE 3.2 – Signal ECG extrait

On remarque que le système produit un signal numérique fidèle à l'original avec :

- Une corrélation $r > 0,85$ sur les données test.
- Une erreur moyenne MAE inférieure à 0,1 après normalisation.
- Conservation des caractéristiques cliniques principales (ondes P, QRS, T).

3.6 Résultats et évaluation des modèles

Nous évaluons les performances de notre modèle de classification ECG selon trois configurations de données : sans augmentation, avec une augmentation à 1 000 segments par classe, puis à 10 000 segments. Nous utilisons une architecture CNN vue dans chapitre 2, puis deux architectures hybrides CNN-LSTM et CNN-GRU sur le jeu de données choisi. L'entraînement a duré 40 époques, avec une taille de batch de 32, un choix standard adapté à la taille des données.

3.6.1 Modèle et configurations de données

Modèle 1 : Résultats sans augmentation des données

Cette première configuration utilise le jeu de données original déséquilibré, sans aucune technique d'augmentation. Les performances du modèle CNN sont résumées dans le tableau suivant :




FIGURE 3.3 – Courbes de loss et d'accuracy- Modèle 1 (CNN sans augmentation).

Ensemble	Nombre	Accuracy	Précision	Recall	F1-score
Train	67 463	0.83	0.65	0.82	0.64
Test	20 399	0.79	0.54	0.52	0.46

TABLE 3.2 – Performances du modèle CNN sans augmentation de données

On voit que le modèle donne des résultats moyens sur le train mais chute en test, en particulier le F1-Score, la métrique qui nous intéresse le plus. Cette chute s'explique par le fort déséquilibre des classes.

Modèle 2 : Résultats avec augmentation à 1 000 segments par classe

Cette deuxième configuration utilise le jeu de données original équilibré (1000 segment par classe) Ce qui revient à appliquer un sous-échantillonnage des classes majoritaires et une augmentation des classes minoritaires. Cette augmentation a été choisie pour équilibrer les classes sans que les données générées dépassent celles d'origine. Les résultats détaillés des performances du modèle sont présentés dans le tableau.




FIGURE 3.4 – Courbes de loss et d'accuracy- Modèle 2 (CNN avec 1k/classe)

D'après les courbes et le tableau, on voit que ce choix n'améliore pas les performances.

Ensemble	Nombre	Accuracy	Précision	Recall	F1-score
Train	5000	0.66	0.64	0.67	0.63
Test	1000	0.62	0.63	0.62	0.60

TABLE 3.3 – Performances d'un modèle complémentaire

Modèle 3 : Résultats avec augmentation à 10 000 segments par classe

Cette configuration augmente massivement le jeu de données à 10 000 segments par classe, permettant un apprentissage plus robuste. Les résultats après cette augmentation sont détaillés dans le tableau.




FIGURE 3.5 – Courbes de loss et d'accuracy- Modèle 3 (CNN avec 10k/classe).

Ensemble	Nombre	Accuracy	Précision	Recall	F1-score
Train	50 000	0.97	0.97	0.96	0.96
Test	20 399	0.95	0.95	0.92	0.94

TABLE 3.4 – Performances du modèle CNN avec augmentation intensive (10k/classe).

L'augmentation intensive donne d'excellents résultats avec un F1-score de 0,94 et une loss de 0,077 sur l'ensemble de test. Les courbes montrent une convergence rapide de l'accuracy vers 97 % et une stabilisation de la perte, avec des évolutions similaires entre entraînement et validation, confirmant l'absence de sur-apprentissage.

Modèle 4 :

Ces modèles combinent les capacités d'extraction de caractéristiques des CNN avec la modélisation séquentielle des RNN (LSTM et GRU). Les performances comparatives des modèles hybrides sont disponibles dans le tableau.




FIGURE 3.6 – Courbes d'entraînement- Modèle CNN-GRU




FIGURE 3.7 – Courbes d'entraînement- Modèle CNN-LSTM

Modèle	Accuracy (Test)	Précision	Recall	F1-score
CNN-LSTM	0.97	0.95	0.93	0.94
CNN-GRU	0.98	0.95	0.94	0.95

TABLE 3.5 – Performances des modèles hybrides

Bien que les modèles hybrides atteignent d'excellentes performances (Accuracy de 0,97 et 0,98), leurs courbes de validation présentent une instabilité caractéristique de la complexité architecturale, rendant l'optimisation plus difficile.

3.7 Matrice de confusion

À partir des deux matrices de confusion, on constate que, pour notre premier ensemble, la classification est quasi parfaite : la majorité des échantillons sont correctement classés. Pour le deuxième ensemble, les résultats diffèrent légèrement, mais restent excellents.

On observe que le modèle peut confondre certains segments de la classe **F** avec les classes **N** ou **V** (0,06 %), ce qui est dû à la rareté de cette classe. Malgré cela, les performances globales demeurent satisfaisantes, ce qui démontre, une fois de plus, la capacité du modèle à généraliser et à produire des prédictions fiables.




FIGURE 3.8 – Matrice de confusion

3.8 Comparaison des performances avec l'état de l'art

TABLE 3.6 – Comparaison des performances de différentes études de classification ECG

Études	Précision (%)	Recall (%)	F1-Score (%)	Accuracy (%)
Liu et al.	99,1	96,5	98,3	97,31
Xuan Hua et al.	nr	97	97	97.45
Notre solution	95	95	92	94

Le tableau ci-dessus présente une comparaison des performances entre notre modèle et plusieurs méthodes vus dans l'état de l'art. Notre approche a obtenu une précision de 96% et un F1-score de 96% sur l'ensemble d'entraînement, et respectivement 95% et 92% sur l'ensemble de test. Cette cohérence entre TRAIN et TEST montre que le modèle apprend efficacement sans surapprentissage excessif, tout en conservant une bonne capacité de généralisation. Bien que certaines études rapportent des scores plus élevés sur certaines métriques, notre solution reste compétitive et équilibrée.

3.9 Présentation de l'interface

CardioNet est un site Web regroupant quatre interfaces. Celle qui nous intéresse est la deuxième : la page d'analyse ECG (fig. 3.9), où le médecin importe un fichier (.png ou .dat) pour obtenir, en quelques secondes, la classe prédite parmi les cinq catégories (N, S, V, F, Q), selon un ordre précis de pourcentages aidant au diagnostic. Le processus est expliqué dans l'annexe(C.3), de même que les autres interfaces et leurs détails C.4



FIGURE 3.9 – Interface d'analyse automatique ECG

3.10 Conclusion

Ce chapitre a mis en évidence la nécessité de réaliser plusieurs tests, tant sur le modèle que sur les données, afin d'atteindre les meilleurs résultats. Par « résultats », on entend à la fois la performance globale, les métriques obtenues, les courbes d'apprentissage et les matrices de confusion.

Ces tests nous ont permis d'identifier le meilleur modèle de classification ECG, lequel a atteint une exactitude de 97 % sur les données d'entraînement et de 95 % sur les données de validation.

Conclusion générale :

Dans ce projet de fin d'étude, nous avons abordé le problème de la classification des anomalies cardiaques à partir des signaux ECG, en exploitant les réseaux de neurones profonds, essentiellement les réseaux convolutifs. Pour concevoir un tel système, nous avons suivi une méthodologie complète. Nous avons d'abord mené une étude approfondie du sujet : notions médicales et de cardiologie, expérimentation sur les signaux ECG, et apprentissage des bases de l'intelligence artificielle et de ses sous-domaines. Ensuite, une fois la théorie acquise, nous sommes passés à la partie pratique, en commençant par le traitement des données, puis l'augmentation, jusqu'à la conception et l'entraînement du modèle. Notre modèle est basé sur un réseau de neurones convolutifs (CNN), comme mentionné précédemment. Nous avons testé plusieurs architectures et configurations de données. Ce travail nous a permis de constater qu'un modèle performant dépend surtout de la qualité et de la quantité des données, ainsi que de la bonne configuration de l'architecture. Plus les données sont nombreuses et cohérentes, meilleurs sont les résultats. Les résultats finaux obtenus sont de 97 % sur l'ensemble d'entraînement et 96 % sur l'ensemble de test, avec une loss de 0,007. Une fois le modèle validé, nous avons développé une interface web destinée aux cardiologues afin de les aider à classer un ECG en entrée et automatiser cette tâche. Les principales difficultés rencontrées lors de ce projet ont été : le prétraitement des données, le temps de calcul important des modèles, le choix des bonnes métriques pour évaluer les résultats, et aussi l'étape de l'augmentation.

Perspectives

- Tester et utiliser des bases de données d'hôpitaux algériens (comme CERIST-CUH Arrhythmia, en cours), avec des battements annotés et validés par au moins deux cardiologues.
- Intégrer d'autres modèles hybrides (comme CNN-LSTM ou CNN-GRU)
- Travailler avec des bases de données plus grandes et variées
- Adapter le système à un usage temps réel sur dispositifs embarqués
- Ajouter la prise en charge des ECG multi-canaux
- Améliorer l'interface pour un usage plus clinique

Bibliographie

- [1] Pastre, J. (1999). *Maîtrise de l'anatomie cardiaque*. Éditions Médicales, Paris.
- [2] Fédération Française de Cardiologie, *L'activité électrique du cœur*, [En ligne]. Disponible sur : <https://www.fedecardio.org/je-m-informe/1-activite-electrique-du-coeur/> (consulté le 18 juin 2025).
- [3] Hampton, J. R. (2013). *The ECG Made Easy*. 8th edition, Churchill Livingstone.
- [4] Kligfield, P., Gettes, L. S., Bailey, J. J., et al. (2007). Recommendations for the standardization and interpretation of the electrocardiogram. *Circulation*, 115(10), 1306-1324.
- [5] Springer Medical Publications. (2023). *Cardiac Conduction System and ECG Patterns*. Medical Imaging Atlas.
- [6] Zipes, D. P., Libby, P., Bonow, R. O., Mann, D. L., Tomaselli, G. F. (2018). *Braunwald's Heart Disease : A Textbook of Cardiovascular Medicine*. 11th edition, Elsevier.
- [7] Russell, S., Norvig, P. (2016). *Artificial Intelligence : A Modern Approach*. 3rd edition, Pearson.
- [8] Szeliski, R. (2010). *Computer Vision : Algorithms and Applications*. Springer-Verlag.
- [9] Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer.
- [10] Sangaiah, A. K., Arumugam, M., Bian, G. B. (2020). An intelligent learning approach for improving ECG signal classification and arrhythmia analysis. *Artificial Intelligence in Medicine*, 103, 101788.
- [11] Alfarsa, F., Hossen, A., Sheltami, T. (2019). Brain-inspired ECG diagnosis using echo state networks. *Biomedical Signal Processing and Control*, 52, 22-29.
- [12] Yang, W., Si, Y., Wang, D., Guo, B. (2020). Automatic recognition of arrhythmia based on principal component analysis network and linear support vector machine. *Computers & Electrical Engineering*, 82, 106554.
- [13] Jha, C. K., Kolekar, M. H. (2020). Tunable Q-wavelet based ECG data compression with validation using cardiac arrhythmia patterns. *Biomedical Engineering Letters*, 10(1), 51-63.
- [14] McCulloch, W. S., Pitts, W. (1943). A logical calculus of the ideas immanent in nervous activity. *The Bulletin of Mathematical Biophysics*, 5(4), 115-133.
- [15] Bastien Maurice. *Fonctionnement du neurone artificiel*. Deeply Learning. Consulté le 28 mai 2025. Disponible sur : <https://deeplylearning.fr/cours-theoriques-deep-learning/fonctionnement-du-neurone-artificiel/>
- [16] Rumelhart, D. E., Hinton, G. E., Williams, R. J. (1986). Learning representations by back-propagating errors. *Nature*, 323(6088), 533-536.
- [17] Haykin, S. (2009). *Neural Networks and Learning Machines*. 3rd edition, Pearson.
- [18] LeCun, Y., Bengio, Y., Hinton, G. (2015). Deep learning. *Nature*, 521(7553), 436-444.
- [19] Cho, K., Van Merriënboer, B., Gulcehre, C., et al. (2014). Learning phrase representations using RNN encoder-decoder for statistical machine translation. *arXiv preprint arXiv :1406.1078*.
- [20] Bengio, Y., Simard, P., Frasconi, P. (1994). Learning long-term dependencies with gradient descent is difficult. *IEEE Transactions on Neural Networks*, 5(2), 157-166.
- [21] Hochreiter, S., Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8), 1735-1780.
- [22] LeCun, Y., Bottou, L., Bengio, Y., Haffner, P. (1998). Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11), 2278-2324.

- [23] Krizhevsky, A., Sutskever, I., Hinton, G. E. (2012). Imagenet classification with deep convolutional neural networks. *Advances in Neural Information Processing Systems*, 25, 1097-1105.
- [24] Goodfellow, I., Bengio, Y., Courville, A. (2016). *Deep Learning*. MIT Press.
- [25] O'Shea, K., Nash, R. (2015). An introduction to convolutional neural networks. *arXiv preprint arXiv :1511.08458*.
- [26] Boureau, Y. L., Ponce, J., LeCun, Y. (2010). A theoretical analysis of feature pooling in visual recognition. *Proceedings of the 27th International Conference on Machine Learning*, 111-118.
- [27] Nair, V., Hinton, G. E. (2010). Rectified linear units improve restricted Boltzmann machines. *Proceedings of the 27th International Conference on Machine Learning*, 807-814.
- [28] Simonyan, K., Zisserman, A. (2014). Very deep convolutional networks for large-scale image recognition. *arXiv preprint arXiv :1409.1556*.
- [29] Yao Zhang, Ali Alavi, and Igor Sbalzarini, *ECG Heartbeat Classification Based on a Multi-Model Feature Fusion Strategy*, arXiv preprint arXiv :2006.11655, 2020. [En ligne]. Disponible sur : <https://doi.org/10.48550/arXiv.2006.11655> (consulté le 18 juin 2025).
- [30] ZHANG, Y., WANG, H., LI, X., & LIU, Y. (2022). Review of ECG detection and classification based on deep learning. *Biomedical Signal Processing and Control*, 71, 103076. <https://doi.org/10.1016/j.bspc.2021.103076>
- [31] REDDY, B. R., & KUMAR, R. L. (2022). Classification of Health care Products using Hybrid CNN-LSTM Model. *Preprint*, ResearchGate. https://www.researchgate.net/publication/366503178_Classification_of_Health_care_Products_using_Hybrid_CNN-LSTM_Model
- [32] EMEKSIZ, C., & FINDIK, M. M. (2022). Hybrid Estimation Model (CNN-GRU) Based on Deep Learning for Wind Speed Estimation. *International Journal of Multidisciplinary Studies and Innovative Technologies*, 6(1), 104–112. https://www.researchgate.net/publication/362147679_Hybrid_Estimation_Model_CNN-GRU_Based_on_Deep_Learning_for_Wind_Speed_Estimation
- [33] G.B. Moody and R.G. Mark, *The impact of the MIT-BIH arrhythmia database*, IEEE Engineering in Medicine and Biology Magazine, vol. 20, no. 3, pp. 45-50, 2001.
- [34] A. Savitzky and M.J.E. Golay, *Smoothing and differentiation of data by simplified least squares procedures*, Analytical Chemistry, vol. 36, no. 8, pp. 1627-1639, 1964.
- [35] S. Mallat, *A Wavelet Tour of Signal Processing : The Sparse Way*, Academic Press, 3rd edition, 2008.
- [36] I. Daubechies, *Ten Lectures on Wavelets*, SIAM, Philadelphia, 1992.
- [37] M. Blanco-Velasco, B. Weng, and K.E. Barner, *ECG signal denoising and baseline wander correction based on the empirical mode decomposition*, Computers in Biology and Medicine, vol. 38, no. 1, pp. 1-13, 2008.
- [38] F. Pedregosa et al., *Scikit-learn : Machine Learning in Python*, Journal of Machine Learning Research, vol. 12, pp. 2825-2830, 2011.
- [39] P. de Chazal, M. O'Dwyer, and R.B. Reilly, *Automatic classification of heartbeats using ECG morphology and heartbeat interval features*, IEEE Transactions on Biomedical Engineering, vol. 51, no. 7, pp. 1196-1206, 2004.
- [40] G. Iglesias, E. Talavera, Á. González-Prieto, A. Mozo, S. Gómez-Canaval. *Data Augmentation techniques in time series domain : a survey and taxonomy*. Neural Computing and Applications, 2023.
- [41] Deepak Kumar Garg, Diksha Thakur, Seema Sharma, Shweta Bhardwaj, *ECG Paper Records Digitization through Image Processing Techniques*, International Journal of Computer Applications, vol. 48, no. 13, pp. 35–38, 2012.
- [42] T. O'Malley et al., *Keras Tuner*, <https://github.com/keras-team/keras-tuner>, 2019.
- [43] C. Thornton, F. Hutter, H.H. Hoos, and K. Leyton-Brown, *Auto-WEKA : Combined selection and hyperparameter optimization of classification algorithms*, Proceedings of the 19th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, pp. 847-855, 2013.
- [44] V. Nair and G.E. Hinton, *Rectified linear units improve restricted boltzmann machines*, Proceedings of the 27th International Conference on Machine Learning (ICML-10), pp. 807-814, 2010.

- [45] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*, MIT Press, 2016.
- [46] S. Ioffe and C. Szegedy, *Batch normalization : Accelerating deep network training by reducing internal covariate shift*, Proceedings of the 32nd International Conference on Machine Learning, pp. 448-456, 2015.
- [47] N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever, and R. Salakhutdinov, *Dropout : A simple way to prevent neural networks from overfitting*, Journal of Machine Learning Research, vol. 15, no. 1, pp. 1929-1958, 2014.
- [48] F. Chollet et al., *Keras*, <https://keras.io>, 2015.
- [49] D.P. Kingma and J. Ba, *Adam : A method for stochastic optimization*, arXiv preprint arXiv :1412.6980, 2014.
- [50] G. B. Moody and R. G. Mark, "The MIT-BIH Arrhythmia Database on CD-ROM and software for use with it," in *Computers in Cardiology 1990*, IEEE Computer Society Press, pp. 185-188, 1990. [Online]. Available : <https://www.physionet.org/physiotools/wfdb.shtml>
- [51] A. L. Goldberger, L. A. N. Amaral, L. Glass, J. M. Hausdorff, P. Ch. Ivanov, R. G. Mark, J. E. Mietus, G. B. Moody, C.-K. Peng, and H. E. Stanley, "PhysioBank, PhysioToolkit, and PhysioNet : Components of a new research resource for complex physiologic signals," *Circulation*, vol. 101, no. 23, pp. e215-e220, 2000. [Online]. Available : <https://physionet.org/content/mitdb/1.0.0/>
- [52] Association for the Advancement of Medical Instrumentation, *Testing and reporting performance results of cardiac rhythm and ST segment measurement algorithms*, ANSI/AAMI EC57 :2012, 2012.
- [53] Epstein, A. E., DiMarco, J. P., Ellenbogen, K. A., et al. (2013). 2012 ACCF/AHA/HRS focused update incorporated into the ACCF/AHA/HRS 2008 guidelines for device-based therapy. *Circulation*, 127(3), e283-e352.
- [54] January, C. T., Wann, L. S., Alpert, J. S., et al. (2014). 2014 AHA/ACC/HRS guideline for the management of patients with atrial fibrillation. *Circulation*, 130(23), e199-e267.
- [55] Priori, S. G., Blomström-Lundqvist, C., Mazzanti, A., et al. (2015). 2015 ESC Guidelines for the management of patients with ventricular arrhythmias. *European Heart Journal*, 36(41), 2793-2867.
- [56] James Lewis, Hafsa Farooq, *Electrocardiogram*, In : StatPearls [Internet]. Treasure Island (FL) : StatPearls Publishing ; 2023. [En ligne]. Disponible sur : <https://www.ncbi.nlm.nih.gov/books/NBK549803/> (consulté le 18 juin 2025).

Annexes

Annexe A

l'état de l'art

A.1 détails des arytmies

A.1.1 Bradycardies

On reconnaît les bradycardies par un rythme cardiaque < 50 BPM :

- Bradycardie sinusale (SBR) : Rythme lent mais régulier.
- - Bloc auriculo-ventriculaire (AV Block) : Retard ou interruption de la voie entre oreillettes et ventricules.

A.1.2 Tachycardies

On reconnaît les tachycardies par leur rythme cardiaque > 100 BPM :

- Tachycardie supraventriculaire (SVT) : Rythme rapide et régulier.
- Fibrillation atriale (AFIB) : Rythme irrégulier des oreillettes[54].
- Flutter atrial (AFL) : Rythme rapide et organisé des oreillettes (250-350 BPM).
- Tachycardie ventriculaire (VT) : Rythme anormalement rapide (>120 BPM).

A.1.3 Troubles Ventriculaires

- Fibrillation ventriculaire (VFIB) : Troubles du rythme ventriculaire.
- Extrasystoles ventriculaires (PVC) : Battements anormaux et prématurés [55].

A.2 Architectures d'un cnn




FIGURE A.1 – Architecture de base d'un CNN

Comparaison des études sur la détection d'arythmies

TABLE A.1 – Comparaison des études sur la détection d'arythmies

Étude	Méthodologies	Database	Classes	Métriques (%)		
				Préc.	Rappel	Acc.
Sangaiah et al. 2020 [10]	Filtre dédié et design des ondelettes + Modèle caché (HMM)	MIT-BIH AD	05	100	99.7	99.7
Alfarsa et al. 2019 [11]	Réseaux d'écho d'état + Apprentissage inspiré du cerveau	MIT-BIH AD	05	95.8	84.4	98.6
Yang et al. 2020 [12]	Segmentation + Réseau neuronal + SVM + KNN	MIT-BIH AD	15	NR	NR	97.70
Jha et al. 2020 [13]	Transformation Q-ondelette ajustable + SVM	MIT-BIH AD	08	NR	96.22	99.27

A.3 ML vs DL :

D'après les travaux que nous venons de cités utilisant des méthodes ML et d'autres DL, nous proposons le tableau comparatif suivant des performances obtenus :

TABLE A.2 – Comparaison entre ML et DL

Critère	ML	DL
Accuracy	81–99.7	91.4–99.84
Recall	81–99.7	81–99.74
Précision	Rarement mentionnée	83–99.87
Extraction des caractéristiques	Manuelle	Automatique
Prétraitement des données	Beaucoup de prétraitement	Prétraitement minimal
Efficacité	Bonne	Supérieure
Données	Traite un petit ensemble de données	Capacité de traiter un jeu de données très volumineux

Annexe B

Conception

B.1 Méthodes d'augmentation

On utilise plusieurs techniques classiques pour augmenter les segments ECG et simuler des variations réalistes : subsection Bruit gaussien : on ajoute un petit bruit aléatoire au signal, comme s'il venait du capteur ou de l'environnement ; subsection Décalage temporel : on décale le signal un peu vers la gauche ou la droite, ça simule un changement de position du battement ; subsection Étirement/Compression : on allonge ou on raccourcit le segment pour représenter des battements plus lents ou plus rapides ; subsection Variation d'amplitude : on change un peu la hauteur des ondes pour représenter des différences d'intensité.

B.2 Architecture détaillée du modèle CNN

TABLE B.1 – Architecture détaillée du modèle CNN

N°	Couche / Traitement	Dimension de sortie
0	Entrée (segment ECG)	360×1
1	Conv1D (48 filtres, 3×1)	358×48
2	Batch Normalization	358×48
3	MaxPooling1D (2×1)	179×48
4	Dropout (rate = 0,25)	179×48
5	Conv1D (64 filtres, 5×1)	175×64
6	Batch Normalization	175×64
7	MaxPooling1D (2×1)	87×64
8	Dropout (rate = 0,25)	87×64
9	Conv1D (64 filtres, 3×1)	85×64
10	Batch Normalization	85×64
11	MaxPooling1D (2×1)	42×64
12	Dropout (rate = 0,25)	42×64
13	Flatten	2 688
14	Dense (ReLU, 96 neurones)	96
15	Dropout (rate = 0,5)	96
16	Dense (Softmax, 5 classes)	5

B.3 Les diagrammes :




FIGURE B.1 – Diagrammes de cas d'utilisation.




FIGURE B.2 – Diagrammes de classes.




FIGURE B.3 – Diagramme de séquence.

Annexe C

Discussion des Résultats :

C.1 Hardware :

- CPU : Intel(R) Core(TM) i7-6600U, 2.60 GHz (jusqu'à 2.81 GHz), 2 cœurs / 4 threads.
- GPU : Intel(R) HD Graphics 520, 128 Mo.
- RAM : 16 Go

C.1.1 Technologies web et base de données

- **PostgreSQL** : Système de gestion de base de données relationnelle open-source, robuste et performant, offrant des fonctionnalités avancées pour le stockage et la gestion des données complexes avec support des requêtes SQL complexes et des extensions spécialisées.
- **Node.js** : Environnement d'exécution JavaScript côté serveur, permettant le développement d'applications web scalables et performantes avec une architecture événementielle non-bloquante.
- **Express.js** : Framework web minimaliste et flexible pour Node.js, facilitant la création d'APIs RESTful et d'applications web avec une gestion simplifiée des routes, middlewares et requêtes HTTP.
- **React.js** : Bibliothèque JavaScript développée par Facebook pour la construction d'interfaces utilisateur interactives et réactives, basée sur une architecture par composants réutilisables.
- **HTML5** : Langage de balisage standard pour la structuration du contenu web, offrant des éléments sémantiques modernes et des fonctionnalités multimédia intégrées.
- **Tailwind CSS** : Framework CSS utility-first permettant la création rapide d'interfaces utilisateur modernes et responsives grâce à des classes utilitaires prédéfinies, offrant une approche efficace pour le développement front-end.

C.2 Tableau récapitulatif des performances des modèles :

TABLE C.1 – Performances des différents modèles de classification ECG

Modèle	Augmentation	Nombre de données	Accuracy Test	F1-score Test
1 / CNN	Non	20399	0.79	0.46
2 / CNN	1k/classe	1000	0.62	0.60
3 / CNN	10k/classe	50000	0.96	0.94
4 / CNN-LSTM	10k/classe	50000	0.97	0.94
5 / CNN-GRU	10k/classe	50000	0.98	0.95

C.3 Procéssus de classification final d'un ecg

Lorsqu'un fichier ECG complet est chargé dans la plateforme CardioNet, celui-ci est tout d'abord segmenté automatiquement en battements (vu dans chapitre conception – segmentation). Ces segments sont ensuite transmis au modèle de classification, qui va prédire pour chaque segment une des cinq classes recommandées par la norme AAMI, N,S,V,F et Q . Après cela, une boucle de comptage est appliquée pour calculer la répartition des prédictions par classe. Ce comptage est ensuite utilisé pour déterminer une classe dominante qui sera la classe finale de cet ECG, à travers une fonction de priorité basée sur des seuils inspirés de la littérature scientifique médicale [56] : Si la classe Q représente plus de 20 % des segments, elle est prioritaire ;,

-Sinon, si V 20 %, elle est choisie ;,

-Puis, si S 5 %, elle est retenue ;,

-Suivie par F 1 %, ou enfin N 80

Si aucun de ces critères n'est satisfait, la classe globale est définie comme inconnue. Ce mécanisme permet de faire un diagnostic fiable qui peut grandement aider le médecin dans son évaluation.

C.4 Présentation de l'interface :

Page d'accueil , qui présente la mission et les fonctionnalités de la plateforme ainsi que des informations sur le service de cardiologie du CHU Mustapha Bach




FIGURE C.1 – page d'accueil.

contient un formulaire patient permettant de saisir les informations médicales du patient, d'ajouter un fichier ECG, et d'obtenir un résultat de classification parmi cinq catégories : N, S, V, F et Q, en fonction de notre processus d'analyse vu précédemment.

Rapport d'analyse ECG

Nom : nassiba

Âge : 22 ans

Email : nassibadjouabi2003@gmail.com

Maladie chronique : rien

Date : 2025-05-28

Motif : rien

Médicaments : rien

Antécédents chirurgicaux : rien

Antécédents familiaux : rien

Résultat : N (Normaux)

Prénom : djoaubi

Téléphone : 0795387943

Médecin : Dr. mohammed

Type d'opération : rien

Télécharger le PDF

FIGURE C.2 – Interface historique des patients — affichage des résultats médicaux.

dédiée à l'historique et la recherche : liste les examens ECG réalisés durant la journée et permet de les filtrer par patient, date ou medecin.

Recherche par :

Nom

Prenom

16/05/2025

Medecin

Rechercher

Résultats de la recherche

NOM	PRÉNOM	MÉDECIN	RÉSULTAT
djouabi	djoaubi	hjs	normal
djouabi	djoaubi	hjs	normal
djouabi	djoaubi	hjs	normal
djouabi	djoaubi	hjs	normal

© 2025 Mustapha Bacha - Cardiologie. Tous droits réservés.

FIGURE C.3 – Interface historique des patients — affichage des résultats médicaux.