

**UNIVERSITÉ DES SCIENCES ET DE LA TECHNOLOGIE
HOUARI BOUMÉDIÈNE**

Faculté d'Informatique
Département d'Informatique

Rapport de Projet

Master 1 — Systèmes Informatiques Intelligents

Module : Réseaux de Neurones

Classification de cultures agricoles par imagerie satellitaire Sentinel-2 avec MCTNet

Réseau CNN-Transformer multi-étage pour
la cartographie des cultures à l'échelle du pixel

Réalisé par :

ACHEROUF KEBIR Sarah
DIF Arslan Aris
ZIANE BERROUDJA Tesnime

Encadré par :

M. Sahnoune Abdel Karim
Mme. Houacine Naila

Année universitaire : 2025 – 2026

Table des matières

Introduction	1
1 Partie 1 — Modèle de base : MCTNet	2
1.1 Revue de littérature	2
1.1.1 Contexte et problématique	2
1.1.2 Analyse du papier MCTNet	2
1.1.3 Positionnement	3
1.2 Acquisition des données	3
1.2.1 Source et régions d'étude	3
1.2.2 Stratégie de zonage	3
1.2.3 Format des données	4
1.2.4 Dimension temporelle	4
1.3 Exploration des données	5
1.3.1 Distribution des classes	5
1.3.2 Profils phénologiques (NDVI)	5
1.3.3 Données manquantes	6
1.4 Prétraitement	7
1.4.1 Construction du masque (Input 2)	7
1.4.2 Normalisation	7
1.4.3 Restructuration en tenseurs	8
1.5 Architecture de MCTNet	8
1.5.1 Vue d'ensemble	8
1.5.2 Bloc CTFusion	8
1.5.3 Module ALPE	9
1.5.4 Bilan paramétrique	9
1.6 Protocole d'entraînement	9
1.7 Résultats	10
1.7.1 Métriques comparatives	10
1.7.2 Courbes d'apprentissage	10
1.7.3 Matrices de confusion	11
1.7.4 Discussion	11

2	Partie 2 — Intégration de covariables environnementales	13
2.1	Présentation et justification des covariables	13
2.1.1	Justification scientifique	14
2.2	Exploration des données	14
2.2.1	Distribution des covariables statiques par région	14
2.3	Prétraitement des covariables	15
2.3.1	Extraction et conversions d'unités	15
2.3.2	Stratégie de split et normalisation	15
2.3.3	Fichiers de sortie	16
2.4	Architecture MCTNetWithCovars	16
2.4.1	Branche Sentinel-2	16
2.4.2	Branche covariables	16
2.4.3	Fusion et classification	17
2.5	Étude d'ablation des covariables environnementales	17
2.5.1	Analyse par groupe de covariables	18
2.5.2	Courbes d'apprentissage	18
2.5.3	Matrices de confusion	19
3	Partie 3 — Contributions	20
3.1	Contribution 1 — GatedMCTNet : fusion dynamique	20
3.1.1	Motivation	20
3.1.2	Architecture — Bloc GatedCTFusion	20
3.1.3	Bilan paramétrique	21
3.1.4	Résultats	22
3.1.5	Discussion	22
3.2	Contribution 2 — MCTNet Multiscale : entraînement deux échelles . .	23
3.2.1	Motivation	23
3.2.2	Architecture	23
3.2.3	Bilan paramétrique	24
3.2.4	Résultats	24
3.2.5	Discussion	24
3.3	Contribution 3 — MCTNetUSkip : connexions skip et covariables . . .	25
3.3.1	Motivation	25
3.3.2	Architecture V1 — MCTNetUSkip (connexions skip légères) . .	25
3.3.3	Architecture V2 — UNetMCTNetWithCovars (encodeur-décodeur + covariables)	26
3.3.4	Résultats — MCTNetUSkip (sans covariables)	27
3.3.5	Résultats — UNetMCTNetWithCovars : étude d'ablation	27
3.3.6	Discussion	28

3.4 Synthèse comparative	29
Conclusion	30
Références	32

Table des figures

1.1	Courbes NDVI moyennes par classe — Arkansas et California.	6
1.2	Taux de données manquantes par pas de temps — Arkansas et California.	7
1.3	Courbes de loss MCTNet — train et validation.	10
1.4	Matrices de confusion — MCTNet sur le test set (Arkansas à gauche, California à droite).	11
2.1	Distribution des covariables statiques (pH, carbone organique, texture USDA, élévation et landforms) par classe de culture pour les deux régions.	14
2.2	Courbes d'apprentissage pour les meilleures configurations de covariables par région. La loss Arkansas descend régulièrement (faible surapprentissage) ; la loss California présente davantage d'oscillations, cohérent avec la plus grande complexité du jeu (6 classes, région géographiquement étendue).	18
2.3	Matrices de confusion comparatives (MCTNet baseline vs meilleure configuration de covariables). En Arkansas, les covariables pédologiques réduisent principalement les confusions entre le riz et les autres céréales. En California, la combinaison complète améliore la discrimination des cultures pérennes (vigne, amandiers).	19
2.4	California — configuration <code>topo</code> seul : la topographie introduit des confusions supplémentaires par rapport au baseline, confirmant son apport limité sans information climatique complémentaire.	19
3.1	Courbes d'apprentissage — MCTNet vs GatedMCTNet (Loss, OA val, F1 val).	22

Liste des tableaux

1.1	Zones d'échantillonnage — Arkansas	4
1.2	Zones d'échantillonnage — California	4
1.3	Distribution des échantillons par classe — Arkansas	5
1.4	Distribution des échantillons par classe — California	5
1.5	Statistiques de données manquantes	6
1.6	Nombre de paramètres de MCTNet	9
1.7	Hyperparamètres (reproduisant la Table 3 de [1])	9
1.8	MCTNet reproduit vs résultats originaux	10
2.1	Récapitulatif des covariables environnementales intégrées au modèle. . .	13
2.2	Fichiers <code>.npy</code> générés par le pipeline de prétraitement.	16
2.3	Étude d'ablation des covariables environnementales.	17
3.1	Paramètres supplémentaires par stage — GatedMCTNet	21
3.2	Comparaison MCTNet vs GatedMCTNet (Arkansas, $N_c = 5$)	21
3.3	MCTNet vs GatedMCTNet — métriques sur le test set	22
3.4	Comparaison du nombre de paramètres (Arkansas, 5 classes).	24
3.5	MCTNet vs MCTNet Multiscale — métriques sur le test set	24
3.6	Bilan paramétrique — MCTNet vs MCTNetUSkip	26
3.7	MCTNet vs MCTNetUSkip — métriques sur le test set	27
3.8	Ablation covariables — Arkansas ($N_c = 5$, MCTNet baseline : OA=0.9603)	28
3.9	Ablation covariables — California ($N_c = 6$, MCTNet baseline : OA=0.9311)	28
3.10	Comparaison globale des trois contributions — Arkansas	29
3.11	Comparaison globale des trois contributions — California	29

Introduction

La cartographie des cultures agricoles à grande échelle est un enjeu central pour la gestion des ressources alimentaires et le suivi environnemental. Les séries temporelles d’images satellitaires multibandes — notamment Sentinel-2 avec ses 10 bandes spectrales et ses revisites décennales — offrent une source d’information riche pour discriminer les cultures par leur signature phénologique. Cependant, la variabilité inter-régionale, les données manquantes liées à la couverture nuageuse, et la diversité des architectures de cultures rendent la tâche de classification difficile.

Ce projet s’inscrit dans le cadre du module *Réseaux de Neurones* et porte sur la classification de cultures agricoles à partir de séries temporelles d’images satellitaires Sentinel-2. Le point de départ est la reproduction et l’analyse du modèle MCTNet (*Multi-stage CNN-Transformer Network*) proposé par Wang et al. [1], qui combine des blocs CNN et Transformer en parallèle pour capturer conjointement les dépendances locales et globales des séries temporelles.

Le travail est organisé en trois parties complémentaires :

- **Partie 1** — Reproduction complète de MCTNet : collecte des données via Google Earth Engine sur deux régions agricoles contrastées (Arkansas, 5 classes ; Californie, 6 classes), exploration et prétraitement, entraînement et évaluation. Les performances obtenues (OA = 0.9603 Arkansas, OA = 0.9311 Californie) sont cohérentes avec les résultats publiés.
- **Partie 2** — Intégration de covariables environnementales : enrichissement du modèle MCTNet par trois groupes de données exogènes (propriétés pédologiques OpenLandMap, variables climatiques ERA5, topographie ETOP01/ALOS) et étude d’ablation systématique sur 7 configurations.
- **Partie 3** — Trois contributions architecturales indépendantes : **GatedMCTNet** (fusion CNN-Transformer dynamique par gate apprise), **MCTNet Multiscale** (branche CNN multi-échelle à trois champs réceptifs), et **MCTNetUSkip** (connexions skip préservant les représentations à haute résolution temporelle, avec extension à un encodeur-décodeur U-Net et covariables).

Chapitre 1

Partie 1 — Modèle de base : MCTNet

1.1 Revue de littérature

1.1.1 Contexte et problématique

La cartographie des cultures agricoles à grande échelle est un enjeu majeur pour la gestion des ressources alimentaires et le suivi environnemental. Les images satellitaires multi-temporelles offrent une couverture spatiale importante, mais leur exploitation nécessite des modèles capables de traiter des séries temporelles bruyantes (nuages, données manquantes) sur de grandes surfaces.

1.1.2 Analyse du papier MCTNet

MCTNet (*Multi-stage CNN-Transformer Network*) [1] propose une architecture légère combinant CNN et Transformer pour la classification pixel par pixel de cultures agricoles à partir de séries temporelles Sentinel-2. Les contributions principales du papier sont :

- **Architecture hybride CNN-Transformer** : un bloc CTFusion traite la série temporelle en deux branches parallèles — une branche CNN pour les motifs locaux, une branche Transformer pour les dépendances long-terme — et fusionne leurs sorties par concaténation.
- **Légèreté** : moins de 57 000 paramètres, contre plusieurs millions pour les modèles concurrents (TransUNet, Swin Transformer), ce qui rend MCTNet déployable sans GPU haut de gamme.
- **Gestion des données manquantes** : le module ALPE (*Adaptive Learnable Positional Encoding*) pondère l’encodage positionnel en fonction d’un masque de disponibilité, atténuant l’impact des observations occultées par des nuages.

- **Performances** : OA de 0.9598 sur Arkansas et 0.9502 sur California, comparables aux modèles nettement plus lourds.

1.1.3 Positionnement

Par rapport aux approches existantes, MCTNet se distingue par son ratio performance/complexité. Les modèles purement CNN (TempCNN [2]) capturent bien les motifs locaux mais peinent sur les dépendances long-terme. Les modèles purement Transformer sont puissants mais coûteux. MCTNet propose un compromis efficace en combinant les deux à chaque stage.

1.2 Acquisition des données

1.2.1 Source et régions d'étude

Les données Sentinel-2 Level-2A ont été acquises via **Google Earth Engine** pour l'année 2021 sur deux régions agricoles américaines aux profils très différents :

- **Arkansas** — état du sud, dominé par des cultures annuelles en rotation (Corn, Cotton, Rice, Soybeans). Climat humide subtropical avec une forte couverture nuageuse en hiver (taux de données manquantes : 23.9 %, dont 3 pas de temps entièrement absents).
- **California** — état de l'ouest, caractérisé par des cultures pérennes (Grapes, Almonds, Pistachios) et irriguées (Rice, Alfalfa). Climat méditerranéen plus favorable à l'observation satellite (taux de données manquantes : 16.1 %).

Les labels de référence proviennent du **Cropland Data Layer (CDL)** de l'USDA (résolution 30 m, confiance $\geq 95\%$), validés par le masque **ESA WorldCover 2021** (classe Cropland).

1.2.2 Stratégie de zonage

L'échantillonnage sur l'état entier provoquait des timeouts Google Earth Engine. La solution adoptée consiste à découper chaque état en petites bounding boxes ($\approx 0.5^\circ \times 0.4^\circ$) ciblant les zones agricoles connues, exporter chaque zone séparément, puis fusionner en Python.

Arkansas — **8 zones** ($250 \text{ pts/classe/zone} \times 8 \text{ zones} \times 5 \text{ classes} = 10\,000$) :

TABLE 1.1 – Zones d'échantillonnage — Arkansas

Zone	Région	Bounding Box
Z1a	Nord-Est (Jonesboro)	[-91.5, 35.5, -91.0, 36.0]
Z1b	Nord-Est	[-91.0, 35.5, -90.5, 36.0]
Z1c	Centre-Est	[-91.5, 35.0, -91.0, 35.5]
Z1d	Centre-Est	[-91.0, 35.0, -90.5, 35.5]
Z2a	Delta Ouest	[-92.5, 34.5, -92.0, 35.0]
Z2b	Delta Central	[-92.0, 34.0, -91.5, 35.0]
Z3a	Sud Delta	[-91.5, 34.0, -91.0, 34.5]
Z3b	Sud-Est	[-91.0, 33.5, -90.5, 34.5]

California — **4 zones** (allocation adaptée : 560 pts/classe pour Z1–Z3, 250 pour Z4, puis sous-échantillonnage à 10 000) :

TABLE 1.2 – Zones d'échantillonnage — California

Zone	Région	Bounding Box
Z1	Sacramento Valley	[-122.2, 38.8, -121.4, 39.6]
Z2	San Joaquin (centre)	[-120.8, 36.8, -119.8, 37.6]
Z3	Fresno / Bakersfield	[-119.8, 35.5, -118.8, 36.3]
Z4	Imperial Valley (alfalfa)	[-115.8, 32.6, -115.2, 33.2]

1.2.3 Format des données

Chaque pixel est décrit par trois tenseurs :

- **input1** : $(N, 10, 36)$ — réflectances normalisées ($\div 10\,000$, puis les valeurs 0 indiquent un pas de temps manquant).
- **input2** : $(N, 36)$ — masque binaire construit avant normalisation : 1 si au moins une bande est non nulle, 0 sinon.
- **labels** : $(N,)$ — indice de classe entier.

1.2.4 Dimension temporelle

L'année 2021 est découpée en **36 fenêtres de 10 jours**. Pour chaque fenêtre, la **médiane** des observations valides (sans nuages) est calculée pixel par pixel. La médiane est préférée à la moyenne pour sa robustesse aux nuages non détectés (valeurs aberrantes) :

$$\text{composite}_t = \text{median}\{x_i \mid x_i \text{ valide dans } [t, t + 10j]\} \quad (1.1)$$

1.3 Exploration des données

1.3.1 Distribution des classes

TABLE 1.3 – Distribution des échantillons par classe — Arkansas

Classe	Total	Train	Val	Test
Soybeans	1 799	240	60	1 499
Rice	2 056	240	60	1 756
Corn	2 056	240	60	1 756
Cotton	2 056	240	60	1 756
Others	2 056	240	60	1 756
Total	10 023	1 200	300	9 723

TABLE 1.4 – Distribution des échantillons par classe — California

Classe	Total	Train	Val	Test
Grapes	1 680	240	60	1 380
Rice	1 126	240	60	826
Alfalfa	1 930	240	60	1 630
Almonds	1 680	240	60	1 380
Pistachios	1 680	240	60	1 380
Others	1 930	240	60	1 630
Total	10 026	1 440	360	8 826

La stratégie de partitionnement est **équilibrée** : 300 pixels par classe sont réservés pour train+val (240/60), indépendamment de l’abondance naturelle de chaque classe. Le reste forme le test set, représentatif de la vraie distribution géographique.

1.3.2 Profils phénologiques (NDVI)

Chaque culture présente une signature temporelle caractéristique. Le pic de NDVI intervient à des moments distincts de l’année. Ces décalages phénologiques constituent l’information discriminante principale exploitée par MCTNet via sa branche Transformer.




FIGURE 1.1 – Courbes NDVI moyennes par classe — Arkansas et California.

1.3.3 Données manquantes

TABLE 1.5 – Statistiques de données manquantes

Région	Taux global	Pas de temps entièrement absents
Arkansas	23.9 %	3 (t3, t15, t34)
California	16.1 %	0




FIGURE 1.2 – Taux de données manquantes par pas de temps — Arkansas et California.

1.4 Prétraitement

1.4.1 Construction du masque (Input 2)

Le masque est construit **avant** toute normalisation. Un pas de temps est considéré manquant si toutes ses bandes valent simultanément 0 (convention GEE pour les fenêtres sans observation valide) :

$$\text{mask}_{n,t} = \begin{cases} 0 & \text{si } \sum_{b=1}^{10} x_{n,b,t} = 0 \\ 1 & \text{sinon} \end{cases} \quad (1.2)$$

Aucune interpolation n'est appliquée sur les valeurs manquantes : les 0 sont conservés dans `input1` et c'est le module ALPE qui se charge de les atténuer lors du traitement.

1.4.2 Normalisation

Sentinel-2 stocke les réflectances sous forme d'entiers multipliés par 10 000. La normalisation divise par cette constante pour ramener les valeurs dans $[0, 1]$:

$$\hat{x}_{n,b,t} = \frac{x_{n,b,t}}{10\,000} \quad (1.3)$$

Les valeurs 0 (données manquantes) restent à 0 après normalisation, ce qui est voulu. Cette opération est appliquée identiquement sur train, val et test, sans fuite de données.

1.4.3 Restructuration en tenseurs

Les CSV exportés depuis GEE sont en format plat (360 colonnes par ligne, nommées selon la convention $B2, B2_1, \dots, B12_35$). La restructuration en tenseurs *channels-first* suit :

$$(N, 360) \xrightarrow{\text{reshape}} (N, 36, 10) \xrightarrow{\text{transpose}} (N, 10, 36) \quad (1.4)$$

Le format $(N, 10, 36)$ est le format *channels-first* attendu par les convolutions 1D de PyTorch.

1.5 Architecture de MCTNet

1.5.1 Vue d'ensemble

MCTNet enchaîne trois blocs CTFusion suivis d'un Global Max Pooling et d'un classificateur linéaire :

$$(B, 10, 36) \xrightarrow{\text{Stage 1}} (B, 20, 18) \xrightarrow{\text{Stage 2}} (B, 40, 9) \xrightarrow{\text{Stage 3}} (B, 80, 4) \xrightarrow{\text{GMP}} (B, 80) \xrightarrow{\text{Linear}} (B, N_c) \quad (1.5)$$

$N_c = 5$ pour l'Arkansas, $N_c = 6$ pour la Californie.

1.5.2 Bloc CTFusion

Le bloc CTFusion est l'unité de base répétée trois fois. Il traite la même entrée en deux branches parallèles puis fusionne leurs sorties :

- **Branche CNN** (ResBlock1D) — deux convolutions 1D de kernel 3 avec connexion résiduelle, capte les motifs locaux de la série temporelle (pics phénologiques, transitions rapides).
- **Branche Transformer** (MHSA, 5 têtes) — modélise les dépendances globales entre pas de temps distants.

Les sorties sont concaténées sur la dimension canaux, puis réduites temporellement par un MaxPool1D (stride 2) :

$$\text{CTFusion}(x) = \text{MaxPool1D}\left(\left[\text{CNN}(x), \text{Transformer}(x) \right]\right) : (B, C, T) \rightarrow (B, 2C, T/2) \quad (1.6)$$

1.5.3 Module ALPE

Au Stage 1 uniquement, un module ALPE (*Adaptive Learnable Positional Encoding*) pondère l’encodage positionnel du Transformer en fonction du masque `input2` :

$$\text{PE_adapté}_t = \text{PE}_t \cdot w_t, \quad w_t = f(\text{input2}_t, \theta_{\text{ALPE}}) \quad (1.7)$$

Les pas de temps couverts par des nuages ($\text{input2}_t = 0$) reçoivent un encodage réduit, limitant leur influence sur les scores d’attention. Cette approche est plus robuste que l’interpolation car elle n’introduit pas de valeurs synthétiques dans les données.

1.5.4 Bilan paramétrique

TABLE 1.6 – Nombre de paramètres de MCTNet

Composant	Arkansas ($N_c = 5$)	California ($N_c = 6$)
CTFusion Stage 1 (incl. ALPE)	9 270	
CTFusion Stage 2	18 860	
CTFusion Stage 3	28 263	
Classifier	405	486
Total	56 798	56 879

1.6 Protocole d’entraînement

TABLE 1.7 – Hyperparamètres (reproduisant la Table 3 de [1])

Paramètre	Valeur
Optimiseur	Adam
Taux d’apprentissage	10^{-3}
Weight decay	10^{-4}
Batch size	64
Époques max	200
Têtes d’attention	5
Kernel Conv1D	3
Dropout	0.1
Early stopping	patience = 20
Scheduler	ReduceLROnPlateau (factor = 0.5)

Le meilleur modèle est sélectionné selon le **F1 macro** sur le jeu de validation. Les métriques finales (OA, Kappa, F1 macro) sont calculées sur le test set avec le meilleur checkpoint.

1.7 Résultats

1.7.1 Métriques comparatives

TABLE 1.8 – MCTNet reproduit vs résultats originaux

Source	Région	OA	Kappa	F1 macro
[1]	Arkansas	0.9598	0.9421	—
Notre reproduction	Arkansas	0.9603	0.9504	0.9603
[1]	California	0.9502	0.9313	—
Notre reproduction	California	0.9311	0.9166	0.9339

1.7.2 Courbes d'apprentissage




FIGURE 1.3 – Courbes de loss MCTNet — train et validation.

1.7.3 Matrices de confusion




FIGURE 1.4 – Matrices de confusion — MCTNet sur le test set (Arkansas à gauche, California à droite).

1.7.4 Discussion

Sur l'Arkansas, la reproduction est fidèle : notre OA (0.9603) dépasse légèrement celle du papier (0.9598), et le Kappa est nettement supérieur (0.9504 vs 0.9421). Cet écart positif sur le Kappa suggère que notre pipeline de collecte et de prétraitement produit des données de qualité comparable, voire légèrement plus propres sur ce jeu.

La matrice de confusion Arkansas confirme une classification quasi-parfaite sur la majorité des classes. Les confusions résiduelles se concentrent entre **Corn** et **Soybeans**, deux céréales annuelles aux dynamiques phénologiques proches (pic NDVI estival décalé de quelques semaines seulement), et entre **Cotton** et **Others**, la classe *Others* regroupant une diversité de cultures qui peuvent localement imiter le profil spectral du coton en début de saison.

Sur la Californie, un écart de -1.9 points d'OA (0.9311 vs 0.9502) est observable. Plusieurs facteurs l'expliquent : le jeu comporte 6 classes au lieu de 5, les cultures pérennes (Grapes, Almonds, Pistachios) présentent des phénologies lentes et partiellement superposées, et les 4 zones de collecte couvrent une région géographiquement plus étendue et climatiquement plus hétérogène que l'Arkansas.

La matrice de confusion California révèle que les principales erreurs concernent précisément ces cultures pérennes : **Grapes**, **Almonds** et **Pistachios** sont partiellement confondus entre elles, leurs profils NDVI étant tous caractérisés par une montée lente au printemps et un maintien prolongé en été. La classe **Rice** est en revanche très bien discriminée grâce à son pic phénologique tardif et marqué, caractéristique du riz irrigué californien.

Les courbes de loss confirment une convergence saine sur les deux régions : les losses train et validation descendent parallèlement jusqu'à l'arrêt précoce, sans signe d'overfitting majeur. La légère oscillation de la loss de validation en Californie est cohérente avec la plus grande difficulté de ce jeu.

Chapitre 2

Partie 2 — Intégration de covariables environnementales

L’objectif de cette seconde phase est de pallier les limites de la discrimination purement spectrale en intégrant des données exogènes. La Partie 1 a établi un pipeline de classification basé exclusivement sur les séries temporelles Sentinel-2. La Partie 2 enrichit ce cadre en adjoignant trois groupes de covariables environnementales : climatiques (ERA5), pédologiques (OpenLandMap) et topographiques (ETOPO1/ALOS). L’objectif est double : (i) mesurer l’apport de chaque groupe de covariables via une ablation study systématique, et (ii) valider la généralisation du modèle sur les deux régions géographiques étudiées en Partie 1.

2.1 Présentation et justification des covariables

Sept covariables environnementales ont été retenues, structurées en trois catégories.

Catégorie	Covariable	Source	Unité / Format
Pédologie (Sol)	pH (<code>ph_b0</code>)	OpenLandMap	pH réel ($\div 10$)
	Carbone Organique (<code>oc_b0</code>)	OpenLandMap	g/kg ($\div 5$)
	Texture (<code>texture_b0</code>)	OpenLandMap	Classe USDA (1–12)
Topographie	Élévation (<code>elevation</code>)	ETOPO1 (NOAA)	Mètres
	Modelé (<code>landforms</code>)	ALOS (CSP/ERGo)	Catégoriel entier
Climat	Température moyenne (<code>T_c</code>)	ERA5 Daily	°C
	Précipitations (<code>P_mm</code>)	ERA5 Daily	mm
	Humidité Relative (<code>RH</code>)	ERA5 Daily	%

TABLE 2.1 – Récapitulatif des covariables environnementales intégrées au modèle.

2.1.1 Justification scientifique

1. Propriétés du sol (soil) : Le pH, le carbone organique et la texture sont retenus pour leur rôle déterminant dans l’aptitude des terres agricoles. La cartographie du carbone organique constitue un indicateur clé de la santé des sols [3]. Ces variables imposent des contraintes biophysiques directes : le riz tolère des sols argileux acides là où le soja nécessite des sols neutres [4].

2. Variables climatiques (clim) : La température, les précipitations et l’humidité relative pilotent la phénologie des cultures. Ces facteurs dictent les cycles de croissance et influencent directement la réponse spectrale captée par Sentinel-2 [1]. L’humidité, étroitement liée aux précipitations, est par ailleurs un facteur critique pour la modélisation par réseaux de neurones [5].

3. Topographie (topo) : L’élévation et les modelés du terrain permettent de distinguer les contextes de drainage et les microclimats locaux (zones de bas-fonds *vs* plateaux), essentiels pour la précision des cartes de cultures à grande échelle [6].

2.2 Exploration des données

2.2.1 Distribution des covariables statiques par région




FIGURE 2.1 – Distribution des covariables statiques (pH, carbone organique, texture USDA, élévation et landforms) par classe de culture pour les deux régions.

Arkansas (Figure 2.1a)

Les cinq cultures analysées en Arkansas (maïs, coton, riz, soja, autres) présentent des profils pédologiques relativement homogènes. Le pH varie entre 5,5 et 6,5 pour la majorité des classes, traduisant des sols légèrement acides typiques des plaines alluviales. Le carbone organique est faible pour toutes les cultures (médiane $\approx 0,4$ – $0,6$ g/kg), avec peu de dispersion. La texture USDA est dominée par des valeurs autour de 7–8, correspondant à des limons argileux. L’élévation est globalement basse et homogène (65–95 m), reflétant la topographie plane du delta du Mississippi. Les *landforms* montrent peu de variabilité inter-classes (25–35), confirmant un terrain peu accidenté.

Californie (Figure 2.1b)

La Californie présente une plus grande hétérogénéité entre classes. Le pH est plus élevé (7,0–8,0), reflétant des sols plus alcalins caractéristiques des vallées irriguées. Le carbone organique reste faible mais avec davantage de valeurs aberrantes, notamment pour la luzerne (*Alfalfa*) et la catégorie *Others*. La texture USDA est très variable selon les cultures. L’élévation est nettement plus dispersée (de -50 à $+200$ m), traduisant la diversité topographique de l’État entre plaines côtières et vallées intérieures.

Synthèse. Ces distributions suggèrent que les covariables statiques ont un pouvoir discriminant limité en Arkansas en raison de l’homogénéité des conditions pédoclimatiques, alors qu’en Californie, l’élévation et la texture constituent des variables potentiellement plus informatives.

2.3 Prétraitement des covariables

2.3.1 Extraction et conversions d’unités

Les colonnes climatiques sont détectées dynamiquement par préfixe : `T_c_*` (température), `P_mm_*` (précipitations), `RH_*` (humidité relative), produisant $36 \times 3 = 108$ dimensions pour les variables climatiques. Les colonnes statiques `ph_b0`, `oc_b0`, `texture_b0`, `elevation` et `landforms` sont extraites par nom.

Deux conversions d’unités physiques fixes sont appliquées avant toute normalisation :

- **pH du sol** (`ph_b0`) : valeurs brutes encodées en $\text{pH} \times 10$. Division par 10 pour ramener à l’unité réelle : $\text{ph_b0} \leftarrow \text{ph_b0}/10$
- **Carbone organique** (`oc_b0`) : valeurs brutes en dg/kg. Division par 5 pour convertir en g/kg : $\text{oc_b0} \leftarrow \text{oc_b0}/5$

Le vecteur de covariables complet résulte de la concaténation des trois groupes :

$$\mathbf{c} = [\mathbf{c}_{\text{clim}} \parallel \mathbf{s}_{\text{sol}} \parallel \mathbf{s}_{\text{topo}}] \in \mathbb{R}^{113} \quad (108 + 3 + 2)$$

Sept configurations sont évaluées dans l’ablation study : `soil` ($K = 3$), `clim` ($K = 108$), `topo` ($K = 2$), `clim_soil` ($K = 111$), `clim_topo` ($K = 110$), `soil_topo` ($K = 5$) et `all` ($K = 113$).

2.3.2 Stratégie de split et normalisation

Le pipeline suit strictement l’ordre suivant pour éviter toute fuite de données :

1. **Split sur données brutes.** Pour chaque classe, $\min(300, |\mathcal{C}|)$ individus sont sélectionnés aléatoirement (graine fixée à 42), puis répartis en train (80 %) et

val (20 %). Les individus restants constituent le jeu de test.

2. **Fit du StandardScaler sur le train uniquement.**

$$\hat{c}_k = \frac{c_k - \mu_k^{\text{train}}}{\sigma_k^{\text{train}}}$$

3. **Transform appliqué sur val et test** avec le même scaler, sans re-fit.

4. **Sauvegarde du scaler** en .pkl pour inférence future.

2.3.3 Fichiers de sortie

Fichier	Forme	Description
*_input1.npy	$(N, 10, 36)$	Bandes S2 normalisées ($\div 10\,000$)
*_input2.npy	$(N, 36)$	Masque données manquantes $\{0, 1\}$
*_covars_all.npy	$(N, 113)$	Toutes covariables (z-score)
*_covars_clim.npy	$(N, 108)$	Covariables climatiques seules
*_covars_soil.npy	$(N, 3)$	Covariables pédologiques seules
*_covars_topo.npy	$(N, 2)$	Covariables topographiques seules
*_covars_clim_soil.npy	$(N, 111)$	Climat + sol
*_covars_clim_topo.npy	$(N, 110)$	Climat + topographie
*_covars_soil_topo.npy	$(N, 5)$	Sol + topographie
*_labels.npy	$(N,)$	Étiquettes de classe
*_covar_scaler.pkl	—	StandardScaler (fitté sur train)

TABLE 2.2 – Fichiers .npy générés par le pipeline de prétraitement.

2.4 Architecture MCTNetWithCovars

2.4.1 Branche Sentinel-2

La branche Sentinel-2 est identique à MCTNet (Partie 1) : trois blocs CTFusion enchaînés suivis d’un Global Max Pooling produisent un vecteur de représentation $\mathbf{f}_{S2} \in \mathbb{R}^{80}$:

$$(B, 10, 36) \xrightarrow{\text{Stage 1}} (B, 20, 18) \xrightarrow{\text{Stage 2}} (B, 40, 9) \xrightarrow{\text{Stage 3}} (B, 80, 4) \xrightarrow{\text{GMP}} (B, 80)$$

2.4.2 Branche covariables

Une branche parallèle traite le vecteur de covariables :

$$\mathbf{f}_{\text{cov}} = \text{Dropout}(\text{ReLU}(W_c \mathbf{c} + b_c)) \in \mathbb{R}^{32}$$

où $\mathbf{c} \in \mathbb{R}^K$ est le vecteur de covariables normalisées ($K \in \{2, 3, 5, 108, 110, 111, 113\}$ selon la configuration d’ablation).

2.4.3 Fusion et classification

Les deux représentations sont concaténées et projetées vers les logits :

$$\hat{\mathbf{y}} = W_{\text{cls}}[\mathbf{f}_{S2} \parallel \mathbf{f}_{\text{cov}}] + b_{\text{cls}} \in \mathbb{R}^{N_c}$$

avec $W_{\text{cls}} \in \mathbb{R}^{N_c \times 112}$ ($80 + 32 = 112$).

2.5 Étude d’ablation des covariables environnementales

L’entraînement est conduit sur les 7 configurations et les 2 régions ($7 \times 2 = 14$ runs indépendants). Le modèle de référence est MCTNet sans covariables (OA = 0.9603 Arkansas, OA = 0.9311 Californie).

TABLE 2.3 – Étude d’ablation des covariables environnementales.

Région	Groupe	OA	Kappa	F1 macro
Arkansas	MCTNet (baseline)	0.9603	0.9504	0.9603
Arkansas	soil	0.9775	0.9719	0.9776
Arkansas	clim	0.9713	0.9641	0.9713
Arkansas	topo	0.9716	0.9646	0.9717
Arkansas	clim_soil	0.9751	0.9688	0.9751
Arkansas	clim_topo	0.9726	0.9657	0.9726
Arkansas	soil_topo	0.9699	0.9624	0.9700
Arkansas	all	0.9772	0.9715	0.9772
California	MCTNet (baseline)	0.9311	0.9166	0.9339
California	soil	0.9326	0.9174	0.9348
California	clim	0.9370	0.9227	0.9396
California	topo	0.9298	0.9139	0.9330
California	clim_soil	0.9360	0.9216	0.9389
California	clim_topo	0.9368	0.9226	0.9394
California	soil_topo	0.9270	0.9105	0.9303
California	all	0.9357	0.9213	0.9372

2.5.1 Analyse par groupe de covariables

Sol (soil). Meilleur résultat Arkansas (OA = 0.9775, +1.72 pts). Les cultures arkansiennes (riz, maïs, coton) sont fortement liées aux caractéristiques hydriques et minérales des plaines alluviales. En Californie, le gain est plus modeste (OA = 0.9326).

Climat (clim). Amélioration sur les deux régions. En Californie, meilleur résultat individuel (OA = 0.9370), confirmant que les conditions thermiques et hydriques saisonnières sont déterminantes pour les cultures pérennes.

Topographie (topo). Gain modéré en Arkansas (OA = 0.9716). En Californie, légère dégradation (OA = 0.9298) : la topographie seule peut introduire du bruit sans information climatique complémentaire.

Combinaisons. `clim_soil` (Arkansas : 0.9751, Californie : 0.9360) montre une bonne complémentarité. L'ensemble complet `all` donne des résultats très élevés (Arkansas : 0.9772) mais légèrement inférieurs à `soil` seul, suggérant que la topographie peut ajouter de la redondance.

2.5.2 Courbes d'apprentissage




FIGURE 2.2 – Courbes d'apprentissage pour les meilleures configurations de covariables par région. La loss Arkansas descend régulièrement (faible surapprentissage) ; la loss Californie présente davantage d'oscillations, cohérent avec la plus grande complexité du jeu (6 classes, région géographiquement étendue).

2.5.3 Matrices de confusion




FIGURE 2.3 – Matrices de confusion comparatives (MCTNet baseline vs meilleure configuration de covariables). En Arkansas, les covariables pédologiques réduisent principalement les confusions entre le riz et les autres céréales. En Californie, la combinaison complète améliore la discrimination des cultures pérennes (vigne, amandiers).




FIGURE 2.4 – Californie — configuration **topo** seul : la topographie introduit des confusions supplémentaires par rapport au baseline, confirmant son apport limité sans information climatique complémentaire.

Chapitre 3

Partie 3 — Contributions

Cette partie présente trois contributions indépendantes apportées à MCTNet, chacune ciblant un aspect différent de l’architecture : la fusion des branches (GatedMCTNet), la résolution temporelle (MCTNet Multiscale), et la préservation des représentations intermédiaires (MCTNetUSkip).

3.1 Contribution 1 — GatedMCTNet : fusion dynamique

3.1.1 Motivation

Dans MCTNet, la fusion CNN-Transformer se fait par simple concaténation : les deux branches contribuent toujours à 50/50, indépendamment du contexte. Or, l’utilité relative du CNN et du Transformer varie selon la culture et le stage :

- Les cultures à cycle court (Rice, Corn) présentent des pics phénologiques nets mieux capturés par les filtres locaux du CNN.
- Les cultures à phénologie progressive (Alfalfa, Grapes) bénéficient davantage de l’attention globale du Transformer.

Idée : remplacer la fusion fixe par une gate apprise qui pondère dynamiquement la contribution de chaque branche en fonction du contenu.

3.1.2 Architecture — Bloc GatedCTFusion

GatedCTFusion remplace CTFusion à chacun des trois stages. La seule modification est l’ajout d’une **gate** entre la sortie des deux branches et leur concaténation.

Flux :

1. CNN et Transformer traitent x en parallèle : $\text{cnn_out}, \text{tr_out} \in \mathbb{R}^{B \times C \times T}$

2. Contexte global par moyenne temporelle :

$$\text{context} = \text{mean}_T\left(\left[\text{cnn_out}, \text{tr_out}\right]\right) \in \mathbb{R}^{B \times 2C} \quad (3.1)$$

3. Calcul de la gate par canal :

$$\alpha = \sigma\left(W_g \cdot \text{context}\right) \in (0, 1)^{B \times C} \quad (3.2)$$

où $W_g \in \mathbb{R}^{C \times 2C}$ est une couche linéaire apprise.

4. Fusion pondérée :

$$\text{fused} = \left[\alpha \cdot \text{cnn_out}, (1 - \alpha) \cdot \text{tr_out}\right] \in \mathbb{R}^{B \times 2C \times T} \quad (3.3)$$

5. MaxPool1D (stride 2) $\rightarrow (B, 2C, T/2)$

La forme de sortie est identique à CTFusion — GatedMCTNet est un remplacement transparent ne nécessitant aucune modification du reste du code.

3.1.3 Bilan paramétrique

La gate W_g ajoute $\text{Linear}(2C, C)$, soit $2C^2 + C$ paramètres par stage :

TABLE 3.1 – Paramètres supplémentaires par stage — GatedMCTNet

Stage	C	Gate ($2C^2 + C$)	Cumul
Stage 1	10	210	210
Stage 2	20	820	1 030
Stage 3	40	3 240	4 270

TABLE 3.2 – Comparaison MCTNet vs GatedMCTNet (Arkansas, $N_c = 5$)

Modèle	Paramètres	Différence
MCTNet	56 798	—
GatedMCTNet	61 068	+4 270 (+7.5%)

3.1.4 Résultats

TABLE 3.3 – MCTNet vs GatedMCTNet — métriques sur le test set

Modèle	Région	OA	Kappa	F1 macro
MCTNet	Arkansas	0.9603	0.9504	0.9603
GatedMCTNet	Arkansas	0.9695	0.9618	0.9696
MCTNet	California	0.9311	0.9166	0.9339
GatedMCTNet	California	0.9237	0.9077	0.9257




FIGURE 3.1 – Courbes d’apprentissage — MCTNet vs GatedMCTNet (Loss, OA val, F1 val).

3.1.5 Discussion

La gate α apprise permet au modèle d’adapter dynamiquement la contribution relative du CNN et du Transformer selon le contexte de chaque stage. Avec seulement 4 270 paramètres supplémentaires (+7.5%), GatedMCTNet conserve la légèreté de MCTNet tout en introduisant une flexibilité de fusion.

En Californie (6 classes, jeu d’entraînement plus petit), une tendance au surapprentissage est observable sur la branche Transformer, la gate ayant besoin de plus d’exemples pour converger vers des poids stables.

3.2 Contribution 2 — MCTNet Multiscale : entraînement deux échelles

3.2.1 Motivation

MCTNet traite chaque pixel indépendamment à une seule résolution temporelle (36 pas de temps). L’hypothèse ici est qu’exposer le modèle à deux granularités temporelles différentes lors de l’entraînement peut améliorer la robustesse des représentations apprises et la généralisation.

3.2.2 Architecture

La branche CNN de chaque bloc CTFusion est remplacée par un module multi-échelle ; toutes les autres composantes (Transformer, ALPE, MaxPool) restent strictement identiques à [1], ce qui garantit que toute différence de performance est directement attribuable à cette seule modification.

Le nouveau module exécute trois ResBlocks 1D en parallèle avec des kernels $k \in \{3, 7, 15\}$, soit des champs réceptifs de 30, 70 et 150 jours. Ce choix est motivé par la phénologie agricole : la floraison est un événement court (~ 2 semaines, $k=3$), la montaison s’étale sur un à deux mois ($k=7$). Pour une entrée $\mathbf{x} \in \mathbb{R}^{B \times C \times T}$:

$$\mathbf{h}_k = \text{ReLU}\left(\text{BN}\left(\text{Conv}_k^{(2)}\left(\text{BN}\left(\text{Conv}_k^{(1)}(\mathbf{x})\right)\right) + \mathbf{x}\right), \quad k \in \{3, 7, 15\} \quad (3.4)$$

Les trois sorties sont concaténées puis projetées par une convolution 1×1 :

$$\text{MSCNN}(\mathbf{x}) = \text{ReLU}(\text{BN}(\text{Conv}_1([\mathbf{h}_3; \mathbf{h}_7; \mathbf{h}_{15}]))) \in \mathbb{R}^{B \times C \times T} \quad (3.5)$$

Le bloc CTFusion conserve sa structure :

$$\text{CTFusion}(\mathbf{x}) = \text{MaxPool}_2([\text{MSCNN}(\mathbf{x}); \text{Transformer}(\mathbf{x})]) \in \mathbb{R}^{B \times 2C \times T/2} \quad (3.6)$$

3.2.3 Bilan paramétrique

TABLE 3.4 – Comparaison du nombre de paramètres (Arkansas, 5 classes).

Modèle	Params CNN	Params Transformer + clf.	Total
MCTNet [1]	12 880	43 918	56 798
MCTNet Multiscale	112 280	43 918	156 198
Différence	+99 400	0	+99 400

L’augmentation est exclusivement localisée dans les branches CNN ($\times 8,7$ pour ce seul composant) ; la partie Transformer reste inchangée.

3.2.4 Résultats

TABLE 3.5 – MCTNet vs MCTNet Multiscale — métriques sur le test set

Modèle	Région	OA	Kappa	F1 macro
MCTNet	Arkansas	0.9603	0.9504	0.9603
MCTNet Multiscale	Arkansas	0.9668	0.9585	0.9671
MCTNet	California	0.9311	0.9166	0.9339
MCTNet Multiscale	California	0.9322	0.9180	0.9349

3.2.5 Discussion

MCTNet Multiscale améliore légèrement la baseline sur les deux régions : +0.65 points de F1 sur Arkansas (0.9671 vs 0.9603) et +0.10 point sur California (0.9349 vs 0.9339). Les gains sont modestes mais cohérents, ce qui valide l’hypothèse multi-échelle sans la survaloriser. Les courbes d’entraînement révèlent cependant un comportement instable : la loss de validation présente des pics ponctuels marqués (epochs 30–50 et 75–100), signe d’un surapprentissage partiel lié au triplement des paramètres CNN ($56\,798 \rightarrow 156\,198$), plus prononcé sur California (validation loss stagnant autour de 0.4) que sur Arkansas (redescendant sous 0.2). La matrice de confusion Arkansas confirme une classification quasi-parfaite sur les classes 1–3 (rappel ≥ 0.98) ; sur California, la confusion principale reste entre les classes 2 et 3 (rappel 0.88 et 0.89), deux cultures aux dynamiques temporelles proches même à plusieurs échelles.

3.3 Contribution 3 — MCTNetUSkip : connexions skip et covariables

3.3.1 Motivation

Dans MCTNet, chaque stage réduit la résolution temporelle par un facteur 2 via MaxPool1D : $T = 36 \rightarrow 18 \rightarrow 9 \rightarrow 4$. L’encodeur final ne conserve que les représentations à basse résolution temporelle (Stage 3, $T = 4$), tandis que les représentations intermédiaires des Stages 1 et 2 — qui encodent des détails phénologiques fins (pics de verdure, transitions rapides) — sont définitivement perdues avant la classification.

Deux améliorations complémentaires sont proposées :

1. **MCTNetUSkip** : réintégrer les représentations intermédiaires par des connexions skip légères vers la couche de classification.
2. **UNetMCTNetWithCovars** : étendre le modèle avec un décodeur U-Net complet et une branche covariables (sol, climat, topographie) pour évaluer l’apport de données auxiliaires.

3.3.2 Architecture V1 — MCTNetUSkip (connexions skip légères)

MCTNetUSkip modifie CTFusionSkip pour sauvegarder la sortie fusionnée *avant* le MaxPool1D à chaque stage. Cette sortie intermédiaire est projetée en vecteur fixe par un Global Max Pooling (GMP) puis concaténée avec la sortie du Stage 3 avant la couche linéaire finale.

Flux de données :

1. Stage 1 : $(B, C_1, 36) \xrightarrow{\text{CTFusion}} (B, 20, 36) \xrightarrow{\text{GMP}} (B, 20)$ *[skip 1]*
2. MaxPool1D $\rightarrow (B, 20, 18)$
3. Stage 2 : $(B, 20, 18) \xrightarrow{\text{CTFusion}} (B, 40, 18) \xrightarrow{\text{GMP}} (B, 40)$ *[skip 2]*
4. MaxPool1D $\rightarrow (B, 40, 9)$
5. Stage 3 : $(B, 40, 9) \xrightarrow{\text{CTFusion}} (B, 80, 4) \xrightarrow{\text{GMP}} (B, 80)$ *[encodeur]*
6. Concaténation : $\left[(B, 20), (B, 40), (B, 80) \right] \rightarrow (B, 140)$
7. Classificateur : $\text{Linear}(140, 64) \rightarrow \text{ReLU} \rightarrow \text{Linear}(64, N_c)$

La modification est minimale : aucun paramètre supplémentaire n’est ajouté dans l’encodeur. Le coût provient uniquement du classificateur élargi.

TABLE 3.6 – Bilan paramétrique — MCTNet vs MCTNetUSkip

Modèle	Paramètres	Différence
MCTNet	56 798	—
MCTNetUSkip	50 842	−5 956 (−10.5 %)

La réduction s’explique par le remplacement du classificateur MCTNet ($\text{GMP} \rightarrow \text{Linear}(80, N_c)$) par une tête plus légère mais plus large en entrée ($\text{Linear}(140, 64) + \text{Linear}(64, N_c)$, soit $9\,024 + 64 \cdot N_c$ paramètres contre $80 \cdot N_c$ dans MCTNet).

3.3.3 Architecture V2 — UNetMCTNetWithCovars (encodeur-décodeur + covariables)

La deuxième variante adopte une architecture encodeur-décodeur complète inspirée de U-Net [7], et intègre une branche covariables distincte.

Encodeur

Identique à MCTNet : trois stages CTFusion avec MaxPool1D (stride 2), produisant les cartes $e_1 \in \mathbb{R}^{B \times 20 \times 36}$, $e_2 \in \mathbb{R}^{B \times 40 \times 18}$, $e_3 \in \mathbb{R}^{B \times 80 \times 9}$.

Goulot d’étranglement

Un bloc CNN résiduel (ResBlock1D) opère sur $(B, 80, 4)$ après un MaxPool1D supplémentaire, constituant la représentation la plus compressée de la série.

Décodeur

Trois blocs UpCTF reconstruisent progressivement la résolution temporelle :

$$\text{UpCTF}(d_{\ell+1}, e_\ell) : \underbrace{d_{\ell+1} \xrightarrow{\text{ConvTranspose1d}(\times 2)} \hat{d}}_{\text{sur-échantillonnage}} \rightarrow [\hat{d}, e_\ell] \rightarrow \text{CTFusion} \quad (3.7)$$

La résolution est restaurée de $T = 4$ à $T = 9$, $T = 18$, puis $T = 36$.

Branche covariables

Les covariables (sol, climat ERA5, topographie) sont concaténées en un vecteur de dimension 113, passé dans un MLP :

$$\text{cov_branch} : \mathbb{R}^{113} \xrightarrow{\text{Linear}(113, 64)} \text{ReLU} \xrightarrow{\text{Linear}(64, 32)} \text{ReLU} \rightarrow \mathbb{R}^{32} \quad (3.8)$$

Fusion finale

La sortie du décodeur $d_1 \in \mathbb{R}^{B \times 10 \times 36}$ est agrégée par GMP en $(B, 10)$, puis concaténée avec la sortie covariables :

$$\mathbf{z} = \left[\text{GMP}(d_1), \text{cov_branch} \right] \in \mathbb{R}^{B \times 42} \xrightarrow{\text{Linear}(42, N_c)} \hat{y} \quad (3.9)$$

Le modèle totalise **113 566 paramètres**, soit environ le double de MCTNet (56 798), le surcoût provenant principalement du décodeur et de la branche covariables.

3.3.4 Résultats — MCTNetUSkip (sans covariables)

TABLE 3.7 – MCTNet vs MCTNetUSkip — métriques sur le test set

Modèle	Région	OA	Kappa	F1 macro
MCTNet	Arkansas	0.9603	0.9504	0.9603
MCTNetUSkip	Arkansas	0.9637	0.9546	0.9640
MCTNet	California	0.9311	0.9166	0.9339
MCTNetUSkip	California	0.9283	0.9133	0.9308

3.3.5 Résultats — UNetMCTNetWithCovars : étude d’ablation

Note. Les résultats ci-dessous concernent **UNetMCTNetWithCovars** (encodeur-décodeur U-Net complet, 113 566 paramètres), qui est une architecture distincte du **MCTNetWithCovars** présenté en Partie 2 (encodeur MCTNet + branche MLP covariables, $\approx 58\,000$ paramètres). Les différences de performances entre les deux ablations reflètent cette différence architecturale.

L’apport de chaque groupe de covariables est évalué par ablation sur sept configurations. Les covariables sont : sol (*sol* : pH, carbone organique, texture — 3 variables), climat (*clim* : ERA5 36 pas $\times$ 3 variables = 108) et topographie (*topo* : altitude, type de relief — 2 variables).

TABLE 3.8 – Ablation covariables — Arkansas ($N_c = 5$, MCTNet baseline : OA=0.9603)

Configuration	OA	Kappa	F1 macro
Sol seul	0.9701	0.9626	0.9702
Climat seul	0.9728	0.9660	0.9729
Topographie seule	0.9756	0.9696	0.9757
Climat + Sol	0.9769	0.9712	0.9770
Climat + Topo	0.9745	0.9681	0.9745
Sol + Topo	0.9785	0.9731	0.9785
Tout (sol+clim+topo)	0.9769	0.9712	0.9770

TABLE 3.9 – Ablation covariables — California ($N_c = 6$, MCTNet baseline : OA=0.9311)

Configuration	OA	Kappa	F1 macro
Sol seul	0.9312	0.9158	0.9332
Climat seul	0.9316	0.9161	0.9355
Topographie seule	0.9276	0.9112	0.9304
Climat + Sol	0.9321	0.9167	0.9354
Climat + Topo	0.9313	0.9159	0.9333
Sol + Topo	0.9313	0.9158	0.9331
Tout (sol+clim+topo)	0.9395	0.9259	0.9421

3.3.6 Discussion

MCTNetUSkip. En Arkansas, la réintégration des représentations intermédiaires via les connexions skip apporte un gain marginal mais consistant (+0.34 pts OA, +0.42 pts Kappa) avec *moins* de paramètres que MCTNet (−5 956, soit −10.5 %). Cela confirme que les représentations à haute résolution temporelle (Stage 1, $T = 36$) encodent des informations phénologiques utiles que la seule sortie du Stage 3 ne retient pas.

En Californie, une légère dégradation est observée (−0.28 pts OA). Avec seulement 6 classes très diversifiées géographiquement (vallées centrale, Sacramento, Imperial), la concaténation brute des trois niveaux de skip peut introduire du bruit supplémentaire, notamment pour les classes à phénologie lente (Almonds, Grapes) dont les caractéristiques discriminantes résident davantage dans les représentations compressées.

Apport des covariables. En Arkansas, toutes les configurations apportent un gain substantiel sur MCTNet (+0.98 à +1.82 pts OA). La configuration optimale est **Sol** + **Topo** (OA = 0.9785), ce qui suggère que la texture et le pH des sols, combinés à la topographie, sont les indicateurs les plus discriminants pour les cultures arkansiennes (soja, riz, coton) fortement liées aux conditions pédologiques des plaines alluviales.

En Californie, les gains individuels sont très faibles (< 0.1 pt), reflétant la plus grande complexité du jeu ($N_c = 6$, disparité géographique). La configuration **Tout** est la seule à dépasser clairement le baseline (OA = 0.9395, +0.84 pts), indiquant qu’aucun seul type de covariable ne suffit : les cultures californiennes (pistaches, amandes, vigne) nécessitent la complémentarité des trois sources.

L’architecture encodeur-décodeur complète (UNetMCTNetWithCovars, 113 566 paramètres) montre que doubler la capacité du modèle par rapport à MCTNet est justifié dès lors qu’on dispose de covariables multi-sources, mais reste excessif pour la série Sentinel-2 seule.

3.4 Synthèse comparative

TABLE 3.10 – Comparaison globale des trois contributions — Arkansas

Modèle	OA	Kappa	F1 macro	Paramètres
MCTNet (baseline)	0.9603	0.9504	0.9603	56 798
GatedMCTNet	0.9695	0.9618	0.9696	61 068
MCTNet Multiscale	0.9668	0.9585	0.9671	156 198
MCTNetUSkip	0.9637	0.9546	0.9640	50 842

TABLE 3.11 – Comparaison globale des trois contributions — California

Modèle	OA	Kappa	F1 macro	Paramètres
MCTNet (baseline)	0.9311	0.9166	0.9339	56 879
GatedMCTNet	0.9237	0.9077	0.9257	61 149
MCTNet Multiscale	0.9322	0.9180	0.9349	156 198
MCTNetUSkip	0.9283	0.9133	0.9308	50 907

Conclusion

Ce projet a permis de reproduire, enrichir et améliorer le modèle MCTNet pour la classification de cultures agricoles à partir de séries temporelles Sentinel-2, à travers trois axes complémentaires.

Partie 1. La reproduction de MCTNet a été menée de bout en bout : collecte GEE sur 8 zones Arkansas et 4 zones Californie, prétraitement (masque données manquantes, normalisation, reshape), et entraînement avec le protocole original. Les performances reproduites ($OA = 0.9603$ / $Kappa = 0.9504$ en Arkansas ; $OA = 0.9311$ / $Kappa = 0.9166$ en Californie) confirment la reproductibilité du modèle et servent de baseline pour toutes les contributions suivantes.

Partie 2. L'intégration de covariables environnementales (sol, climat ERA5, topographie) dans une variante MCTNetWithCovars apporte des gains substantiels en Arkansas (jusqu'à +1.72 pts OA avec les seules propriétés pédologiques), région où les cultures sont fortement contraintes par les conditions des plaines alluviales. En Californie, seule la combinaison complète des trois groupes dépasse clairement le baseline (+0.46 pts OA), reflétant la plus grande diversité géographique et la présence de cultures pérennes.

Partie 3. Trois contributions architecturales ont été évaluées :

- **GatedMCTNet** améliore la baseline de +0.92 pts OA en Arkansas avec seulement 4 270 paramètres supplémentaires (+7.5%). En Californie, la gate nécessite davantage de données pour converger, entraînant une légère régression.
- **MCTNet Multiscale** apporte des gains modestes mais cohérents sur les deux régions (+0.65 pts F1 Arkansas, +0.10 pts F1 Californie), au prix d'une multiplication par 2.75 du nombre de paramètres ($56\,798 \rightarrow 156\,198$), avec un risque accru de surapprentissage.
- **MCTNetUSkip** réintègre les représentations intermédiaires des stages 1 et 2 via des connexions skip légères, améliorant les résultats en Arkansas (+0.34 pts OA) avec *moins* de paramètres que MCTNet. Son extension en encodeur-décodeur U-Net avec covariables atteint $OA = 0.9785$ en Arkansas (configuration Sol+Topo) et $OA = 0.9395$ en Californie (configuration complète).

Choix du modèle. En termes de rapport performance/coût, **GatedMCTNet** constitue la contribution architecturale la plus efficiente : il améliore significativement la

baseline sur la région principale avec un surcoût paramétrique minimal, et son principe de pondération dynamique est bien ancré dans la diversité phénologique des cultures. Si des covariables environnementales sont disponibles, **UNetMCTNetWithCovars** avec la configuration Sol+Topographie représente le meilleur résultat absolu obtenu dans ce projet (OA = 0.9785 en Arkansas).

Limites. Plusieurs points méritent d’être nuancés. Aucune contribution n’améliore de façon significative les résultats en Californie — GatedMCTNet et MCTNetUSkip y régressent même légèrement — ce qui suggère que les gains observés en Arkansas sont en partie liés à l’homogénéité de cette région et ne se généralisent pas à un contexte géographiquement plus complexe. Par ailleurs, tous les modèles ont été évalués sur des jeux d’échantillons limités (240 à 560 pixels par classe), rendant les conclusions sensibles au tirage aléatoire. Enfin, l’évaluation reste purement pixel-based et ne tient pas compte du contexte spatial, ce qui peut avantager les classes dominantes sur les zones homogènes.

Perspectives. La prochaine étape naturelle serait d’intégrer la gate de GatedMCTNet dans l’architecture UNetMCTNetWithCovars, permettant au modèle d’arbitrer simultanément entre CNN et Transformer, et entre série temporelle et covariables. Une régularisation plus forte (dropout sur la branche Transformer, augmentation temporelle) permettrait également de stabiliser l’apprentissage en Californie, où le surapprentissage reste le principal obstacle à la généralisation.

Références

- [1] Zhen WANG et al. “A lightweight CNN-Transformer network for pixel-based crop mapping using time-series Sentinel-2 imagery”. In : *International Journal of Applied Earth Observation and Geoinformation* (2024).
- [2] Charlotte PELLETIER, Geoffrey I. WEBB et François PETITJEAN. “Temporal Convolutional Neural Network for the Classification of Satellite Image Time Series”. In : *Remote Sensing* 11.5 (2019), p. 523.
- [3] G. OU et al. “Improving Soil Organic Carbon Mapping in Farmlands Using Machine Learning”. In : *Environmental Sciences Europe* (2024).
- [4] R. TUFAIL et al. “Deep Learning Applications for Crop Mapping Using Multi-Temporal Sentinel-2 Data”. In : *Remote Sensing* (2025).
- [5] X. JIAO et al. “Multi-Layer Soil Moisture Profiling Based on BKA-CNN”. In : *Agronomy* (2025).
- [6] E. ADRAH et al. “Integrating GEDI, Sentinel-2, and Sentinel-1 for Tree Crops Mapping”. In : *Remote Sensing of Environment* (2025).
- [7] Olaf RONNEBERGER, Philipp FISCHER et Thomas BROX. “U-Net : Convolutional Networks for Biomedical Image Segmentation”. In : *Medical Image Computing and Computer-Assisted Intervention* (2015), p. 234-241.